

Módulo 1 - Repaso de Inferencia Bayesiana

Eel II 2026

Clase 1 - 6/8/26

Cuando escuchan la expresión

Inferencia Bayesiana

¿qué palabras o ideas se les vienen a la cabeza?

Cuando escuchan la expresión

Inferencia Bayesiana

¿qué palabras o ideas se les vienen a la cabeza?

Prior

Incertidumbre

Posterior

Actualización

Probabilidad

Evidencia

¿Por qué empezamos repasando?

La idea NO es volver a cursar Bayes

Queremos asegurarnos de que todos comenzamos el cuatrimestre con las mismas herramientas.

Durante esta materia vamos a construir modelos mucho más complejos.

Para eso necesitamos tener bien presentes algunas ideas fundamentales.

Hoy vamos a recordar las ideas... **que vamos a usar durante todo el curso.**

1763

Thomas Bayes



1812

Pierre-Simon Laplace



Siglo XX

Predominio del enfoque frecuentista



Hoy

Machine Learning ■ IA ■ Medicina ■ Economía

1763

Thomas Bayes



1812

Pierre-Simon Laplace



Siglo XX

Predominio del enfoque frecuentista



Hoy

Machine Learning ■ IA ■ Medicina ■ Economía

La estadística bayesiana se volvió protagonista gracias al crecimiento del poder computacional.

¿Qué cambia respecto del enfoque clásico?

Frecuentista	Bayesiano
Los parámetros son constantes	Los parámetros son variables aleatorias
No incorpora información previa	Puede incorporar conocimiento previo
Produce estimaciones puntuales	Produce distribuciones posteriores
Intervalos de confianza	Intervalos creíbles

La mayor diferencia está en **cómo interpretamos la incertidumbre.**

Tengo una moneda.

¿Creen que está cargada?

La mayor diferencia está en **cómo interpretamos la incertidumbre.**

Tengo una moneda.

¿Creen que está cargada?

La primera respuesta es...

La mayor diferencia está en **cómo interpretamos la incertidumbre.**

Tengo una moneda.

¿Creen que está cargada?

La primera respuesta es...

NO LO SABEMOS

Supongamos que lanzamos la moneda 10 veces.

Cara Cara Cara Cara Cara Cara Cara Cara Cruz Cara

Supongamos que lanzamos la moneda 10 veces.

Cara Cara Cara Cara Cara Cara Cara Cara Cruz Cara

¿Cambió nuestra opinión?

Supongamos que lanzamos la moneda 10 veces.

Cara Cara Cara Cara Cara Cara Cara Cara Cruz Cara

¿Cambió nuestra opinión?

Eso es exactamente lo que hace la Inferencia Bayesiana.

Información previa

+

Datos observados

=

Conocimiento actualizado

Información previa

+

Datos observados

=

Conocimiento actualizado

¡Eso es hacer Inferencia Bayesiana!

$$\text{Posterior} \propto \text{Likelihood} \times \text{Prior}$$

Recordemos que el Teorema de Bayes nos dice:

$$p(\theta|Y) = \frac{p(Y|\theta)p(\theta)}{p(Y)}$$

Recordemos que el Teorema de Bayes nos dice:

$$p(\theta|Y) = \frac{p(Y|\theta)p(\theta)}{p(Y)}$$

Es muy importante tener presente la siguiente fórmula

Recordemos que el Teorema de Bayes nos dice:

$$p(\theta|Y) = \frac{p(Y|\theta)p(\theta)}{p(Y)}$$

Es muy importante tener presente la siguiente fórmula

$$\underbrace{\text{Posterior}}_{\text{lo que creemos ahora}} = \frac{\overbrace{\text{Likelihood}}^{\text{lo observado}} \times \overbrace{\text{Prior}}^{\text{lo que creíamos antes}}}{\underbrace{\text{Evidencia}}_{\text{normaliza}}}$$

Antes de trabajar con modelos complejos...

todo modelo bayesiano necesita responder cuatro preguntas:

1. ¿Qué creemos antes de observar los datos?
2. ¿Qué datos observamos?
3. ¿Cómo actualizamos nuestras creencias?
4. ¿Qué concluimos?

Primer ingrediente: el Prior

¿Qué representa?

Nuestro conocimiento (o nuestras creencias) antes de observar datos.

Primer ingrediente: el Prior

¿Qué representa?

Nuestro conocimiento (o nuestras creencias) antes de observar datos.

Puede provenir de:

- ▶ Experimentos anteriores.

¿Qué representa?

Nuestro conocimiento (o nuestras creencias) antes de observar datos.

Puede provenir de:

- ▶ Experimentos anteriores.
- ▶ Conocimiento experto.

¿Qué representa?

Nuestro conocimiento (o nuestras creencias) antes de observar datos.

Puede provenir de:

- ▶ Experimentos anteriores.
- ▶ Conocimiento experto.
- ▶ Literatura científica.

¿Qué representa?

Nuestro conocimiento (o nuestras creencias) antes de observar datos.

Puede provenir de:

- ▶ Experimentos anteriores.
- ▶ Conocimiento experto.
- ▶ Literatura científica.
- ▶ O simplemente representar incertidumbre.

¿Qué representa?

Nuestro conocimiento (o nuestras creencias) antes de observar datos.


Puede provenir de:

- ▶ Experimentos anteriores.
- ▶ Conocimiento experto.
- ▶ Literatura científica.
- ▶ O simplemente representar incertidumbre.

No siempre sabemos mucho... y eso también puede modelarse.


No todos los priors dicen lo mismo

Prior uniforme – $P(\theta) \sim \text{Beta}(1, 1)$




Poco conocimiento previo

Prior concentrado – $P(\theta) \sim \text{Beta}(20, 20)$




Mucha confianza en un valor

No todos los priors dicen lo mismo



Poco conocimiento previo



Mucha confianza en un valor

Importante

Elegir un prior significa representar cuánto creemos conocer antes de observar datos.

Segundo ingrediente: la Likelihood

La likelihood responde una única pregunta:

Si el parámetro fuera θ ...

¿qué tan probables serían los datos observados?

Segundo ingrediente: la Likelihood

La likelihood responde una única pregunta:

Si el parámetro fuera θ ...

¿qué tan probables serían los datos observados?

No habla del parámetro.

Habla de los datos.

¿Qué hace la Likelihood?

La likelihood no responde

"¿Cuál es el parámetro?"

¿Qué hace la Likelihood?

La likelihood no responde

"¿Cuál es el parámetro?"

Sino

"Si θ fuera cierto...

¿qué tan compatibles serían estos datos?"

¿Qué hace la Likelihood?

La likelihood no responde

"¿Cuál es el parámetro?"

Sino

"Si θ fuera cierto...

¿qué tan compatibles serían estos datos?"

Es una función que mide compatibilidad.

La distribución posterior

Es nuestro conocimiento actualizado después de observar los datos.

Todo lo que queramos estimar proviene del posterior.

Media.

Moda.

Intervalos creíbles.

Predicciones.

Comparaciones.

Volvamos al ejemplo de la moneda

Supongamos que queremos estimar


$$\theta = P(\text{cara})$$

Antes de lanzar la moneda...
tenemos un prior.

Después de observar resultados...
calculamos la likelihood.


Finalmente obtenemos un posterior para θ .

Como vimos, nuestra creencia cambia



Al observar más datos,
el posterior se vuelve cada vez más informativo.

¿Qué ocurre cuando aumenta el tamaño muestral?



Más datos $\implies$ menos incertidumbre

El posterior se concentra alrededor del verdadero parámetro.

¿Y todo esto cómo lo hacemos en la práctica?

Modelo $\longrightarrow$ PyMC $\longrightarrow$ Posterior $\longrightarrow$ Conclusiones

Durante este cuatrimestre

Aprenderemos a construir modelos probabilísticos utilizando **PyMC**, una de las bibliotecas más utilizadas para Inferencia Bayesiana.

¿Cuál de las siguientes afirmaciones es correcta?

1. El prior cambia cuando observamos datos.
2. El posterior resume nuestro conocimiento actualizado.
3. La likelihood representa nuestras creencias previas.
4. El parámetro observado genera la muestra.

$$P(\theta | Y) \propto P(Y | \theta) P(\theta)$$




$$\theta \in [0, 1]$$

$$P(Y | \theta)$$

$$\theta_n \rightarrow \theta$$
$$n = 1, 2, 3, \dots$$

$$P(Y) = \int P(Y | \theta) P(\theta)$$



A partir de la próxima clase...

Comenzaremos a estudiar cómo construir cada uno de estos componentes para resolver problemas reales mediante programación probabilística.

Supongamos tres situaciones.

1. Una moneda recién comprada.

Supongamos tres situaciones.

1. Una moneda recién comprada.
2. Una moneda utilizada por un mago.

Supongamos tres situaciones.

1. Una moneda recién comprada.
2. Una moneda utilizada por un mago.
3. Una moneda de un casino.

¿Usarían el mismo prior en los tres casos?