

Repaso de Estadística

Eel II 2026

Clase 0

- ▶ Repaso de conceptos claves de Probabilidad y Estadística.
- ▶ La Estadística como ciencia que se ocupa de la recopilación, organización, análisis e interpretación de datos numéricos para tomar decisiones informadas y resolver problemas.
- ▶ Repaso de estimación paramétrica y no paramétrica.
- ▶ Fundamentos teóricos de IC y Test de Hipótesis.

Fundamentos de la Estadística:

- ▶ **Base matemática:** se apoya en conceptos y herramientas matemáticas para el análisis de datos
- ▶ **Recopilación y organización de datos:** obtención de datos relevantes y su estructuración para facilitar su análisis.
- ▶ **Análisis e interpretación:** extracción de información significativa de los datos y comprensión de patrones y relaciones.
- ▶ **Toma de decisiones:** toma de decisiones basadas en evidencia y reducción de *incertidumbre*
- ▶ **Generalización y predicción:** inferir conclusiones sobre poblaciones más amplias y realizar predicciones, a partir del análisis de muestras.

Dado un espacio muestral Ω y dos eventos $A, B \in \Omega$ tal que $P(B) \neq 0$

- ▶ Se define la **Probabilidad Condicional de A dado B** como:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

- ▶ **Regla de la Multiplicación:**

$$P(A \cap B) = P(A|B)P(B)$$

$$P(A \cap B) = P(B|A)P(A)$$

- ▶ **Teorema de Bayes:**

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Teorema de Probabilidad Total. Si $A_1, A_2, \dots, A_n$ representan una partición del espacio muestral Ω , tales que $P(A_i) \neq 0$ para todo i . Entonces, para cualquier evento B , se cumple:

$$P(B) = P(B|A_1)P(A_1) + \dots + P(B|A_n)P(A_n) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

Teorema de Bayes (generalizado). Si $A_1, A_2, \dots, A_n$ representan una partición del espacio muestral Ω , donde $P(A_i) > 0$ para todo i , y sea B un evento cualquiera con $P(B) > 0$, entonces para cualquier $k = 1, \dots, n$, se cumple:

$$P(A_k|B) = \frac{P(B|A_k)P(A_k)}{\sum_{i=1}^n P(B|A_i)P(A_i)}$$

La *función de distribución acumulada* de una v.a. X se define como:

$$F(x) = P(X \leq x) \quad \text{para todo } x \in \mathbb{R}$$

* Para el caso X discreta:

$$F(x) = \sum_{k \leq x} f(k)$$

donde $k \in R_x$ y f es la *función de frecuencia de probabilidad*

* Para el caso X continua:

$$F(x) = \int_{-\infty}^x f(t) dt$$

donde f es la *función de densidad de probabilidad*

- Sea X una v.a. *discreta* con rango R_X . Definimos la Esperanza de X

$$E(X) := \sum_{x \in R_X} x \cdot P(X = x)$$

- Sea X una v.a. *continua*. Definimos la Esperanza de X

$$E(X) := \int xf(x)dx$$

donde f es la *función de densidad de probabilidad*

- Definimos la *Varianza* de X :

$$Var(X) := E[(X - E(X))^2] = E(X^2) - E(X)^2$$

Supongamos que tenemos n variables aleatorias independientes entre sí, $X_1, \dots, X_n$, tales que cada $X_i \sim N(\mu_i, \sigma_i^2)$, $i = 1, \dots, n$. Y sean los coeficientes reales $a_1, a_2, \dots, a_n$. Entonces,

$$a_1.X_1 + a_2.X_2 + \dots + a_n.X_n \sim N(\mu_c, \sigma_c^2)$$

donde:

$$\mu_c = a_1.\mu_1 + a_2.\mu_2 + \dots + a_n.\mu_n$$

$$\sigma_c^2 = a_1^2.\sigma_1^2 + a_2^2.\sigma_2^2 + \dots + a_n^2.\sigma_n^2$$

¿Qué sucede cuando no conocemos la distribución de las v.a. o no tienen distribución normal? Veamos casos particulares en los que vamos a poder utilizar el siguiente teorema:

Ahora sí: recordemos lo que nos dice el TCL

Sean n v.a., $X_1, X_2, \dots, X_n$ independientes entre sí y con la misma distribución, con media μ y desviación típica σ . Entonces si n es grande:

- ▶ $\bar{X}$ tiene *aproximadamente* una distribución normal con media μ y desviación típica $\frac{\sigma}{\sqrt{n}}$ [esto se escribe: $\bar{X} \approx N(\mu, \sigma^2/n)$].
- ▶ Del mismo modo $\sum_{i=1}^n X_i$ también tiene distribución *aproximadamente* normal con media $n\mu$ y desviación típica $\sqrt{n}\sigma$ [esto se escribe: $\sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2)$]

Luego, obtenemos:

- ▶ $P(\bar{X} \leq a) = P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq \frac{a - \mu}{\sigma/\sqrt{n}}\right) \approx \Phi\left(\frac{a - \mu}{\sigma/\sqrt{n}}\right)$
- ▶ $P(\sum_{i=1}^n X_i \leq a) = P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq \frac{a - n\mu}{\sqrt{n}\sigma}\right) \approx \Phi\left(\frac{a - n\mu}{\sqrt{n}\sigma}\right)$

Ejemplo: Simulación del Teorema Central del Límite

Veamos un ejemplo manual en el aplicamos TCL para el promedio de variables aleatorias:

tomamos un conjunto de muestras aleatorias con distribución exponencial (que en particular no es simétrica), pero las medias muestrales siguen una forma aproximadamente normal cuando el tamaño de muestra es grande ($n=40$)

Ejemplo de simulación TCL

- ▶ Un **vector aleatorio** de dimensión n es:

$$\mathbf{X} = (X_1, X_2, \dots, X_n)$$

- ▶ Sus propiedades conjuntas incluyen:

- ▶ Medias individuales: $E[X_i]$
- ▶ Varianzas individuales: $\text{Var}(X_i)$
- ▶ Covarianzas entre componentes: $\text{Cov}(X_i, X_j)$

- ▶ La **matriz de covarianza** del vector es:

$$\Sigma = \text{Cov}(\mathbf{X}) = E \left[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T \right]$$

donde $\mu = E[\mathbf{X}]$ es el vector de medias.

► Covarianza:

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$

Mide la relación lineal entre las variables aleatorias X e Y .

► Correlación:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

Es una medida de relación lineal normalizada. Satisface: $\rho \in [-1, 1]$.

► Independencia vs. No correlación:

- Si X y Y son independientes, entonces $\text{Cov}(X, Y) = 0$
- Pero $\text{Cov}(X, Y) = 0$ **no implica** independencia

- ▶ En estadística inferencial, es común suponer que los datos provienen de una población que sigue una cierta **distribución de probabilidad**, con parámetros desconocidos.
- ▶ **Ejemplo clásico:** $X_1, X_2, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$, donde se asume que los datos son i.i.d. según una normal, pero se desconoce el valor de los parámetros μ y σ^2 .
- ▶ **Objetivo principal:** estimar los parámetros de la distribución que generan los datos.
- ▶ **Métodos de estimación más utilizados:**
 - ▶ **Máxima verosimilitud (ML):** busca el valor de los parámetros que hace más probable la muestra observada.
 - ▶ **Método de los momentos:** iguala los momentos teóricos con los empíricos para obtener estimaciones.

Solo mencionamos la idea principal de cada método:

- ▶ **Máxima Verosimilitud (ML):** se elige el valor de los parámetros que hace máxima la función de verosimilitud:

$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

- ▶ **Método de los momentos:** iguala momentos poblacionales con muestrales.

- ▶ **Sesgo:** diferencia entre el valor esperado del estimador y el verdadero parámetro:

$$\text{Sesgo}(\hat{\theta}) = E(\hat{\theta}) - \theta$$

- ▶ **Varianza:** medida de la dispersión del estimador:

$$\text{Var}(\hat{\theta}) = E[(\hat{\theta} - E(\hat{\theta}))^2]$$

- ▶ **Error Cuadrático Medio (ECM):**

$$\text{ECM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{Sesgo}^2(\hat{\theta})$$

- ▶ Al estimar un parámetro poblacional θ , no todos los estimadores son igual de buenos. Por eso evaluamos sus **propiedades deseables**.

- ▶ **Consistencia:**

$$\hat{\theta}_n \xrightarrow{P} \theta \quad \text{cuando } n \rightarrow \infty$$

El estimador converge en probabilidad al verdadero valor del parámetro a medida que crece el tamaño muestral.

- ▶ **Un teorema útil:** si $\hat{\theta}_n$ es insesgado y su varianza tiende a cero, entonces $\hat{\theta}_n$ es consistente.

- ▶ **Eficiencia:**

estimador insesgado $\hat{\theta}$ se dice eficiente si es el que tiene menor varianza entre todos los de la familia de estimadores insesgados para θ .

(Más adelante retomaremos estas definiciones)

- ▶ Un **intervalo de confianza** busca contener al parámetro poblacional con una probabilidad preestablecida $(1 - \alpha)$.
Al intervalo de confianza que contiene al parámetro θ , con probabilidad $1 - \alpha$, lo denotaremos como $IC_{(1-\alpha)}(\theta)$.
- ▶ Se construye a partir de:
 - ▶ La información sobre la distribución de los datos.
 - ▶ Estadísticos empíricos: media muestral, varianza, proporciones, etc.
 - ▶ Un **pivote** cuya distribución es conocida.
- ▶ Casos típicos:
 - ▶ Para μ con σ conocida o desconocida.
 - ▶ Para σ^2 , con μ conocida o desconocida.
 - ▶ Asintóticos: binomial, Poisson, exponencial.

Tests de hipótesis: estructura general

- ▶ Se formula una **hipótesis nula** (H_0) y una **alternativa** (H_1).
- ▶ Se calcula una **estadística de test**, función de los datos que resume la evidencia contra H_0 .
- ▶ Se define una **región de rechazo** basada en un nivel de significancia α .
- ▶ Posibles errores:
 - ▶ Tipo I: rechazar H_0 siendo verdadera (α).
 - ▶ Tipo II: no rechazar H_0 siendo falsa (β).
- ▶ **Potencia**: $1 - \beta$, probabilidad de detectar un efecto real.
- ▶ **p-Valor** probabilidad de obtener un resultado tan extremo como el observado, bajo H_0 . Si es menor que α , se rechaza H_0 .
- ▶ Casos clásicos: para μ , σ^2 , proporciones, diferencias de medias, y casos asintóticos.
- ▶ Casos de IC y Test de Hipótesis que más conocidos