

Módulos 1 y 2 - Programando en perspectiva bayesiana

Eel II 2026

Clase 2 - 11/8/26

¿Qué podemos hacer con el posterior?

Ya obtuvimos una distribución posterior para θ .

Ahora queremos aprender a:

- ▶ interpretar su forma;
- ▶ resumir nuestra incertidumbre;
- ▶ hacer predicciones.

Hoy

No vamos a volver a construir el posterior. Vamos a aprender a **usarlo**.

La Beta: otra forma de interpretarla

En lugar de trabajar directamente con α y β , podemos escribir:

$$\alpha = \mu\kappa, \quad \beta = (1 - \mu)\kappa$$

donde:

- ▶ μ : media de la distribución;
- ▶ κ : concentración.

Idea

μ determina **dónde** se concentra la distribución, mientras que κ determina **cuánto**.

Un ejemplo

Supongamos:

$$\mu = 0.5, \quad \kappa = 40$$

Entonces:

$$\alpha = 0.5(40) = 20$$

$$\beta = (1 - 0.5)(40) = 20$$

Por lo tanto: Beta(20, 20)

Interpretación

El centro está en 0.5 y la distribución está bastante concentrada alrededor de ese valor.

¿Qué significa κ ?

$$\kappa = \alpha + \beta$$

En el modelo Beta–Binomial, puede interpretarse como una **cantidad equivalente de información previa**.

Por ejemplo:

$$\mu = 0.5, \quad \kappa = 40$$

representa un prior con una fuerte concentración alrededor de 0.5.

A mayor κ , mayor concentración del prior.

Exploren ustedes:


- ▶ Modificá μ y observá qué sucede con el centro de la distribución.
- ▶ Modificá κ y observá qué sucede con su dispersión.
- ▶ Compará distribuciones con distintos niveles de concentración.

En Google Colab

```
pz.Beta(a,b).plot_interactive(...)
```

La idea es interpretar la distribución, no el código.

¿Qué pasa cuando cambiamos μ y κ ?



Cambiar μ mueve la distribución.

Cambiar κ modifica su concentración.

Tenemos una distribución, no un único valor

Nuestro posterior no nos dice simplemente:

$$\theta = 0.5$$

Nos dice cómo se distribuye nuestra incertidumbre sobre θ .

Entonces podemos preguntar:

¿Qué valores de θ son más plausibles?

¿Y qué rango de valores concentra la mayor parte de nuestra incertidumbre?

HDI = *Highest Density Interval*

Es un intervalo que contiene una determinada proporción de la masa posterior, buscando la región de mayor densidad.

$HDI_{95\%}$

contiene el 95% de la masa posterior.

En nuestro ejemplo

Nos permite resumir un rango plausible para la probabilidad θ de obtener cara.

¿Cómo lo interpretamos?

Supongamos que obtenemos:

$$HDI_{95\%} = [0.42, 0.68]$$

Entonces:


El 95% de la masa de la distribución posterior se encuentra entre 0.42 y 0.68.

En nuestro problema:

$$\theta \in [0.42, 0.68]$$

representa un rango plausible para la probabilidad de obtener cara.

Otro ejemplo



Hasta ahora preguntamos:

¿Qué podemos decir sobre θ ?

Ahora queremos hacer una pregunta diferente:

¿Qué podríamos observar en un nuevo experimento?

Esto nos lleva a las

distribuciones predictivas.

Sobre parámetros	Sobre datos
A priori	Predictiva a priori
A posteriori	Predictiva a posteriori

Sobre parámetros	Sobre datos
A priori	Predictiva a priori
A posteriori	Predictiva a posteriori

La diferencia clave

Las distribuciones a priori y a posteriori hablan sobre θ .

Las predictivas hablan sobre **datos que podríamos observar**.

Antes de observar los datos:

$$p(y^*) = \int p(y^* | \theta) p(\theta) d\theta$$

Nos preguntamos:

¿Qué datos podría generar nuestro modelo antes de observar nada?

Esto nos permite revisar si nuestras creencias previas son razonables.

Supongamos que antes de lanzar la moneda creemos que:

$$\theta \sim \text{Beta}(\alpha, \beta)$$

Podemos simular:

$$\theta \longrightarrow Y^*$$

y preguntarnos:

¿Qué cantidad de caras genera nuestro modelo?

Después de observar los datos, reemplazamos el prior por el posterior:

$$p(\tilde{y} | y) = \int p(\tilde{y} | \theta) p(\theta | y) d\theta$$

Ahora preguntamos:

¿Qué datos esperamos observar en futuros experimentos?

¿Cómo generamos una predictiva?

1. Simulamos un valor de θ desde el posterior.

$$\theta^* \sim p(\theta \mid y)$$

¿Cómo generamos una predictiva?

1. Simulamos un valor de θ desde el posterior.

$$\theta^* \sim p(\theta \mid y)$$

2. Generamos datos utilizando ese θ^* .

$$\tilde{y} \sim p(\tilde{y} \mid \theta^*)$$

¿Cómo generamos una predictiva?

1. Simulamos un valor de θ desde el posterior.

$$\theta^* \sim p(\theta \mid y)$$

2. Generamos datos utilizando ese θ^* .

$$\tilde{y} \sim p(\tilde{y} \mid \theta^*)$$

3. Repetimos muchas veces.

¿Cómo generamos una predictiva?

1. Simulamos un valor de θ desde el posterior.

$$\theta^* \sim p(\theta \mid y)$$

2. Generamos datos utilizando ese θ^* .

$$\tilde{y} \sim p(\tilde{y} \mid \theta^*)$$

3. Repetimos muchas veces.

Resultado

Obtenemos una distribución de resultados que nuestro modelo considera plausibles para futuros experimentos.

Supongamos que ya observamos:

$$N = 10, \quad y = 7$$

y obtuvimos una distribución posterior para θ .

Ahora preguntamos:

¿Qué esperamos obtener en nuevos lanzamientos?

No queremos solamente un valor esperado.

Queremos una distribución de posibles resultados.

Ya podemos generar datos desde nuestro modelo.

Pero ahora preguntamos:

¿Se parecen a los datos reales?

Datos observados $\longleftrightarrow$ Datos simulados

Si nuestro modelo genera resultados muy diferentes a los observados, tenemos algo que revisar.

¿Qué estamos comprobando?

Al simular datos desde el modelo podemos observar:

- ▶ qué resultados considera plausibles;
- ▶ qué tan variables pueden ser;
- ▶ si los datos observados parecen razonables bajo el modelo.

¿Qué estamos comprobando?

Al simular datos desde el modelo podemos observar:


- ▶ qué resultados considera plausibles;
- ▶ qué tan variables pueden ser;
- ▶ si los datos observados parecen razonables bajo el modelo.

Idea

No buscamos que los datos simulados sean idénticos a los observados.

Buscamos que los datos observados sean **compatibles** con lo que el modelo puede generar.

¿Qué nos cuenta esta simulación sobre nuestro modelo?



Posterior



¿Qué sabemos sobre θ ?



HDI

¿Qué tan inciertos estamos?



Predictiva

¿Qué esperamos observar?



¿El modelo genera datos razonables?

Inferencia Bayesiana

No se trata solamente de encontrar un valor para un parámetro.

Se trata de:

- ▶ cuantificar nuestra incertidumbre;
- ▶ actualizarla con los datos;
- ▶ resumirla de manera interpretable;
- ▶ utilizarla para hacer predicciones.

Y todo comienza con el posterior.