In [1]:
```
import numpy as np
import matplotlib.pyplot as plt
```

1) Comparación de grupos

Vamos a trabajar con dos grupos y a comparar sus resultados.

Supongamos que tenemos:

- **Grupo A:** estudiantes que utilizaron el método tradicional.
- **Grupo B:** estudiantes que utilizaron un nuevo método.

Vamos a utilizar datos sintéticos para calcular:

1. La diferencia de medias.
2. El d de Cohen.
3. La probabilidad de superioridad.

Finalmente, vamos a visualizar los dos grupos.

1. Generamos datos sintéticos

Para comenzar, vamos a simular los puntajes de dos grupos.

Supondremos que:

- el Grupo A tiene una media aproximada de 70;
- el Grupo B tiene una media aproximada de 78;
- ambos grupos tienen una desviación estándar aproximada de 10;
- tenemos 40 estudiantes en cada grupo.

La función `np.random.default_rng()` nos permite utilizar un generador de números aleatorios con una semilla fija, de modo que podamos reproducir los mismos resultados.

In [12]:
```
rng = np.random.default_rng(42)

# Datos sintéticos
grupo_A = rng.normal(70, 10, 40)
grupo_B = rng.normal(78, 10, 40)
```

2. Diferencia de medias

Una primera forma de comparar los grupos es calcular la diferencia entre sus medias:

$$\Delta = \bar{x}_B - \bar{x}_A$$

Una diferencia positiva indica que, en promedio, el Grupo B presenta valores mayores que el Grupo A.

In [13]:
```
# Diferencia de medias
diff = grupo_B.mean() - grupo_A.mean()
```

Antes de hablar de Cohen, veamos simplemente cuánto difieren las medias:

In [4]:
```
print(f"Media del Grupo A: {grupo_A.mean():.2f}")
print(f"Media del Grupo B: {grupo_B.mean():.2f}")
print(f"Diferencia de medias: {diff:.2f}")
```

```
Media del Grupo A: 70.38
Media del Grupo B: 78.13
Diferencia de medias: 7.75
```

3. Desviación estándar combinada

Para calcular el d de Cohen necesitamos una medida de la variabilidad conjunta de los dos grupos.

Utilizamos la **desviación estándar combinada**:

$$s_{\text{pooled}} = \sqrt{\frac{(n_A - 1)s_A^2 + (n_B - 1)s_B^2}{n_A + n_B - 2}}$$

Esta medida combina la variabilidad de ambos grupos teniendo en cuenta el tamaño de cada uno.

In [5]:
```
# Desviación estándar combinada
n_A = len(grupo_A)
n_B = len(grupo_B)

s_pooled = np.sqrt(
    ((n_A - 1) * grupo_A.var(ddof=1) +
     (n_B - 1) * grupo_B.var(ddof=1))
    / (n_A + n_B - 2)
)
```

Esta es la medida de variabilidad que vamos a utilizar como referencia para estandarizar la diferencia:

In [6]:
```
print(f"Desviación estándar combinada: {s_pooled:.2f}")
```

```
Desviación estándar combinada: 7.79
```

4. d de Cohen

Ahora podemos calcular el tamaño del efecto mediante el **d de Cohen**:

$$d = \frac{\bar{x}_B - \bar{x}_A}{s_{\text{pooled}}}$$

El d de Cohen expresa la diferencia entre las medias en unidades de desviación estándar.

Por ejemplo, un valor de:

$$d = 0.8$$

indica que las medias están separadas por aproximadamente 0.8 desviaciones estándar.

In [7]:
```
# d de Cohen
d = diff / s_pooled

print(f"d de Cohen: {d:.2f}")
```

```
d de Cohen: 0.99
```

Hasta acá tenemos una diferencia de medias y una medida estandarizada de esa diferencia...

5. Probabilidad de superioridad

Ahora queremos expresar la diferencia de una manera diferente.

Nos preguntamos:

$$P(X_B > X_A)$$

Es decir:

> ¿Cuál es la probabilidad de que una observación elegida al azar del Grupo B sea mayor que una observación elegida al azar del Grupo A?

Para estimarla con nuestros datos, vamos a comparar cada observación del Grupo B con cada observación del Grupo A.

Si tenemos 40 observaciones en cada grupo, realizamos:

$$40 \times 40 = 1600$$

comparaciones.

In [8]:
```
# Probabilidad de superioridad
comparaciones = grupo_B[:, None] > grupo_A[None, :]
prob_superioridad = comparaciones.mean()

print(f"Probabilidad de superioridad: {prob_superioridad:.2f}")
```

```
Probabilidad de superioridad: 0.76
```

6. A modo de resumen

In [9]:
```
print(f"Diferencia de medias: {diff:.2f}")
print(f"d de Cohen: {d:.2f}")
print(f"Probabilidad de superioridad: {prob_superioridad:.2f}")
```

```
Diferencia de medias: 7.75
d de Cohen: 0.99
Probabilidad de superioridad: 0.76
```

Podemos resumir la comparación mediante tres cantidades:

- **Diferencia de medias:** expresa la diferencia en las unidades originales.
- **d de Cohen:** expresa la diferencia en unidades de desviación estándar.
- **Probabilidad de superioridad:** expresa la proporción de comparaciones en las que una observación del Grupo B supera a una del Grupo A.

Las tres medidas describen la diferencia entre los grupos desde perspectivas diferentes.

7. Visualizamos los grupos

Finalmente, podemos visualizar la distribución de los puntajes de ambos grupos mediante histogramas.

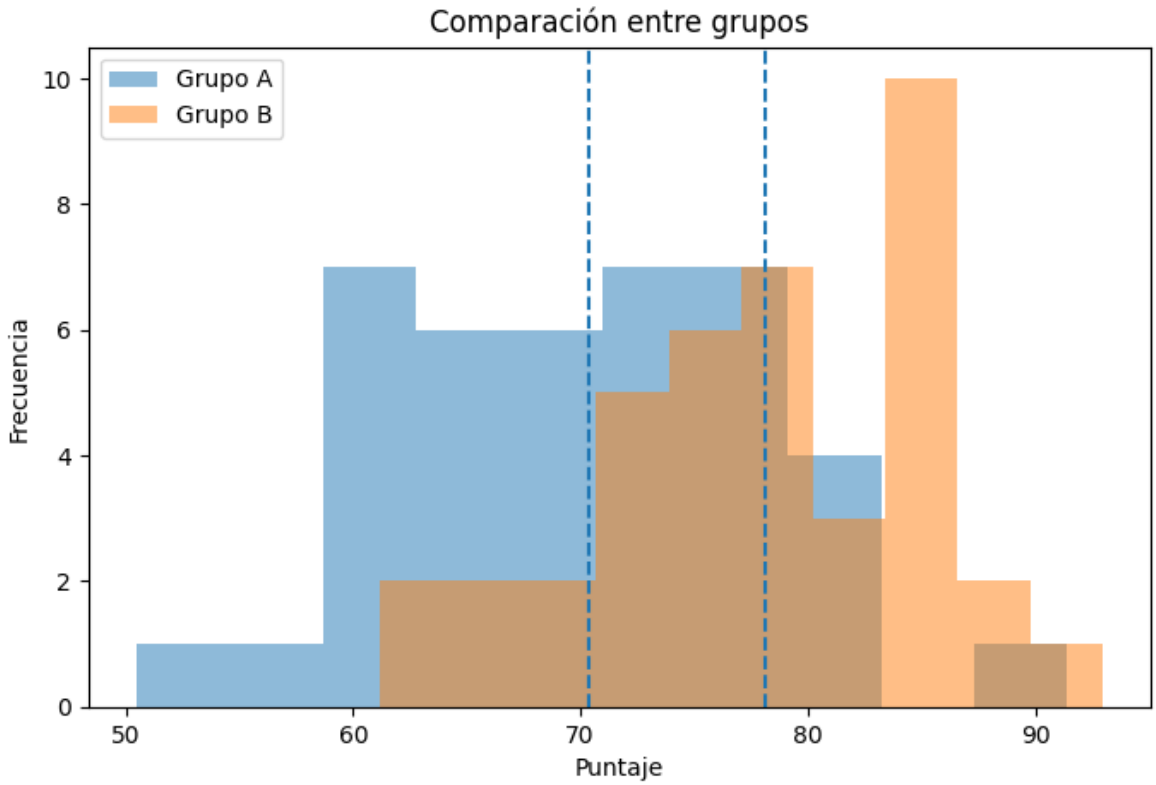
También vamos a marcar sus medias con líneas verticales.

In [10]:
```
plt.figure(figsize=(8, 5))

plt.hist(grupo_A, alpha=0.5, label="Grupo A")
plt.hist(grupo_B, alpha=0.5, label="Grupo B")

plt.axvline(grupo_A.mean(), linestyle="--")
plt.axvline(grupo_B.mean(), linestyle="--")

plt.xlabel("Puntaje")
plt.ylabel("Frecuencia")
plt.title("Comparación entre grupos")
plt.legend()
plt.show()
```



¿Qué podemos observar?

El gráfico nos permite ver:

- cómo se distribuyen los valores de cada grupo;
- dónde se encuentran aproximadamente sus medias;
- cuánto se superponen las distribuciones.

La diferencia entre las medias nos da una primera descripción, mientras que el d de Cohen y la probabilidad de superioridad nos permiten expresar esa diferencia de otras maneras.