


Flujo de trabajo bayesiano - primeras predicciones

Eel II 2026

Clase 6 - 25/8/26

¿Qué hacemos después de ajustar un modelo?




La inferencia bayesiana no termina al obtener una distribución posterior.

Necesitamos evaluar si el modelo es razonable y útil.

El flujo de trabajo bayesiano

si es necesario,
volver atrás




Los modelos son aproximaciones

Una idea fundamental

Un modelo estadístico no es la realidad.

Es una representación simplificada que nos permite:

- ▶ incorporar supuestos,
- ▶ cuantificar incertidumbre,
- ▶ generar predicciones,
- ▶ realizar inferencias.




*La pregunta no es si el modelo es
"verdadero".*

**La pregunta es si resulta adecuado
para nuestro propósito.**

¿Qué cree el modelo antes de ver los datos?

La **distribución predictiva a priori** describe los datos que el modelo considera plausibles antes de observarlos.


$$p(y^*) = \int_{\Theta} p(y^* | \theta) p(\theta) d\theta$$



Sorteamos parámetros y, a partir de ellos, simulamos datos.

Repetimos el procedimiento muchas veces para obtener una distribución de valores que el modelo considera plausibles. Esto permite detectar consecuencias del modelo que sean **poco plausibles** antes de observar los datos reales.

Si simuláramos datos desde nuestro modelo...



Preguntas:

- ▶ ¿Los valores son plausibles?
- ▶ ¿La escala es razonable?
- ▶ ¿Aparecen resultados extremos?
- ▶ ¿El comportamiento coincide con nuestro conocimiento del problema?

Idea clave

Si el modelo genera datos que ya consideramos absurdos **antes de observar los datos**, tenemos un problema con el modelo o con nuestros supuestos.


¿Qué ocurre después de observar los datos?

Una vez observados los datos, actualizamos nuestras creencias:


$$p(\theta | y) \propto p(y | \theta)p(\theta)$$

y podemos generar nuevos datos desde la distribución predictiva **a posteriori**:

$$p(\tilde{y} | y) = \int p(\tilde{y} | \theta)p(\theta | y) d\theta$$



Ahora podemos comparar las simulaciones con los datos observados.



La idea

Si el modelo es adecuado, los datos que genera deberían **reproducir características importantes de los datos observados**.

Podemos comparar, por ejemplo:

$$T(y) \quad \text{vs.} \quad T(\tilde{y})$$

Tendencia central

Dispersión

Asimetría


Colas

Proporciones

Podemos resumir la comparación mediante una cantidad como:

$$p_B = P(T(\tilde{y}) \leq T(y) \mid y)$$


- ▶ $T(y)$ es el estadístico observado,
- ▶ $T(\tilde{y})$ es el mismo estadístico calculado sobre datos simulados,
- ▶ la distribución de comparación es la **predictiva posterior**.



Un Bayesian p-value **¡no es un p-value frecuentista!**

Otra posibilidad es evaluar cada observación: $P(\tilde{y}_i \leq y_i | y)$

Esto nos indica dónde se ubica cada observación dentro de su distribución predictiva.




Si el modelo representa adecuadamente los datos, esperamos que estas posiciones relativas cubran aproximadamente el intervalo $[0,1]$ de manera uniforme.

$$X \sim F_X \quad \implies \quad F_X(X) \sim U[0, 1]$$

Esta es la intuición detrás de la transformada integral de probabilidad (PIT).

¿Y si tenemos varios modelos?

Supongamos que tenemos distintas representaciones plausibles del mismo fenómeno.



No buscamos simplemente el modelo que **mejor reproduce los datos utilizados para ajustarlo**.

Buscamos un equilibrio entre:


Complejidad

¿Necesitamos realmente toda la estructura que propone el modelo?

Predicción

¿Qué tan bien esperamos que funcione frente a nuevos datos?

Ajustar bien no siempre significa predecir bien



Underfitting

- ▶ Muy poca flexibilidad.
- ▶ No captura patrones relevantes.

Overfitting

- ▶ Excesiva flexibilidad.
- ▶ Ajusta también el ruido.

¿Qué modelo esperamos que generalice mejor a datos nuevos?