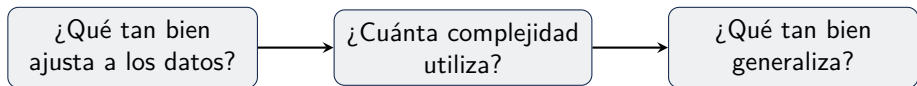


Flujo de trabajo bayesiano - comparación de modelos

Eel II 2026

Clase 7 - 27/8/26

¿Cómo comparamos modelos?



Los criterios de información buscan combinar:

calidad del ajuste + penalización por complejidad

Idea central

No queremos solamente un modelo que explique bien los datos que ya observamos, sino uno que tenga buenas perspectivas de **predecir datos nuevos**.

Del error de predicción a la probabilidad

Supongamos que observamos y_i y que nuestro modelo produce una predicción $E(y_i | \theta)$. Una medida conocida de discrepancia es el error cuadrático medio:

$$\text{ECM} = \frac{1}{N} \sum_{i=1}^N [y_i - E(y_i | \theta)]^2$$

El cuadrado:

- ▶ evita que errores positivos y negativos se cancelen;
- ▶ penaliza especialmente los errores grandes.

¿Por qué medir la discrepancia de esta manera?: Podríamos utilizar muchas funciones de error diferentes.

En un modelo probabilístico

En lugar de comparar solamente un dato con un valor predicho, podemos preguntarnos:

¿Qué probabilidad asigna el modelo a los datos observados?

Validación cruzada: evaluar datos no utilizados

La validación cruzada busca estimar cómo se comportaría un modelo frente a datos que **no participaron de su ajuste**.

En ***K*-fold cross-validation**:

1. Dividimos los datos en K subconjuntos.
2. Dejamos uno fuera.
3. Ajustamos el modelo con los $K - 1$ restantes.
4. Evaluamos el modelo sobre el subconjunto dejado fuera.
5. Repetimos hasta utilizar cada subconjunto como evaluación.

Obtenemos K medidas de desempeño que podemos combinar.

entrenamiento	→	datos no utilizados
---------------	---	---------------------

Después de comparar

Una vez seleccionado el modelo, normalmente volvemos a ajustarlo utilizando **todos los datos disponibles**.

Leave-One-Out Cross-Validation

Un caso particular de K -fold aparece cuando:

$$K = N$$

Cada subconjunto contiene una única observación. Para cada i :

ajustamos con y_{-i} y evaluamos sobre y_i

donde

$$y_{-i} = (y_1, \dots, y_{i-1}, y_{i+1}, \dots, y_N).$$

LOOCV = Leave-One-Out Cross-Validation

El problema: Para N observaciones necesitamos realizar N ajustes del modelo.

$$N \text{ datos} \Rightarrow N \text{ modelos ajustados}$$

Esto puede resultar especialmente costoso en modelos bayesianos, donde cada ajuste puede requerir MCMC.

Entropía: una medida de incertidumbre

Para una distribución discreta $p = (p_1, \dots, p_N)$, definimos su entropía como:

$$H(p) = - \sum_{i=1}^N p_i \log p_i = -\mathbb{E}_p[\log p]$$

Dos casos extremos:

► **Poca incertidumbre:** Si un único resultado ocurre con probabilidad uno,

$$p = (1, 0, \dots, 0), \quad H(p) = 0.$$

► **Máxima incertidumbre:** Si todos los resultados son igualmente probables,

$$p_i = \frac{1}{N}, \quad H(p) = \log N.$$

Cuanto más repartida está la probabilidad entre los resultados posibles, mayor es la incertidumbre y mayor es la entropía.

De la entropía a la divergencia de Kullback–Leibler

Supongamos que q es la distribución objetivo y p una aproximación a ella.
La divergencia de Kullback–Leibler es:

$$KL(q\|p) = \sum_{i=1}^N q_i \log \frac{q_i}{p_i} = \mathbb{E}_q[\log q] - \mathbb{E}_q[\log p]$$

Mide cuánto perdemos al representar q mediante p .

$$KL(q\|p) \geq 0$$

y $KL(q\|p) = 0$ si y solo si $p = q$ casi en todas partes.

¿Por qué podemos comparar modelos sin conocer q ?

Supongamos varios modelos:

$$p_1(y \mid \theta_1), \quad p_2(y \mid \theta_2), \quad \dots, \quad p_M(y \mid \theta_M).$$

Para cada modelo:

$$KL(q \parallel p_m) = \mathbb{E}_q[\log q] - \mathbb{E}_q[\log p_m(Y \mid \theta_m)].$$

El primer término es el mismo para todos los modelos:

$$\mathbb{E}_q[\log q]$$

Por lo tanto:

$$\min_m KL(q \parallel p_m) \iff \max_m \mathbb{E}_q[\log p_m(Y \mid \theta_m)]$$

La dificultad

No conocemos q , la distribución verdadera que genera los datos. Además, si utilizamos los mismos datos para ajustar y evaluar el modelo, obtenemos una estimación **optimista** de su desempeño predictivo.

El criterio de información de Akaike se define como:

$$AIC = -2 \log L(\hat{\theta}_{MLE}) + 2k$$

- ▶ $L(\hat{\theta}_{MLE})$: verosimilitud maximizada;
- ▶ k : número de parámetros.

Tiene dos componentes:

$$\underbrace{-2 \log L(\hat{\theta}_{MLE})}_{\text{calidad del ajuste}} + \underbrace{2k}_{\text{penalización por complejidad}}$$

$$\text{Menor AIC} \Rightarrow \text{modelo preferido}$$

Intuición

Agregar parámetros suele mejorar el ajuste, pero también puede favorecer el sobreajuste. AIC intenta compensar ambas cosas.

¿Por qué AIC no es ideal para un modelo bayesiano?

AIC trabaja con una única estimación: $\hat{\theta}_{MLE}$

Pero en un modelo bayesiano tenemos: $p(\theta | y)$ es decir, una **distribución completa** de valores plausibles para los parámetros.

Además, AIC utiliza: $k =$ **número de parámetros**

mientras que en un modelo bayesiano la complejidad efectiva puede ser diferente del número nominal de parámetros.

Por ejemplo:

- ▶ un prior puede restringir fuertemente un parámetro;
- ▶ una estructura jerárquica puede compartir información;
- ▶ algunos parámetros pueden estar prácticamente determinados por los datos.

¿Podemos construir un criterio que utilice directamente la distribución a posteriori?

En un modelo bayesiano podemos integrar la incertidumbre sobre θ :

$$\sum_{i=1}^N \log \int p(y_i | \theta) p(\theta | y) d\theta$$

Esta cantidad se conoce como: ELPD, es decir, ***Expected Log Predictive Density***.

Con S muestras posteriores $\theta^{(1)}, \dots, \theta^{(S)}$:

$$\widehat{\text{ELPD}}_{\text{in}} = \sum_{i=1}^N \log \left[\frac{1}{S} \sum_{s=1}^S p(y_i | \theta^{(s)}) \right]$$

Pero...

Seguimos utilizando los mismos datos para ajustar y evaluar. Necesitamos una corrección por el optimismo.

WAIC: incorporar la complejidad efectiva

WAIC utiliza la variabilidad posterior de la log-verosimilitud para construir una penalización:

$$WAIC = \sum_{i=1}^N \log \left[\frac{1}{S} \sum_{s=1}^S p(y_i | \theta^{(s)}) \right] - p_{WAIC}$$

$$p_{WAIC} = \sum_{i=1}^N \text{Var}_s \left[\log p(y_i | \theta^{(s)}) \right]$$

El término p_{WAIC} representa una medida de **complejidad efectiva**.

$$WAIC = \underbrace{\text{capacidad predictiva}}_{\text{ELPD dentro de muestra}} - \underbrace{\text{complejidad efectiva}}_{\text{penalización}}$$

A diferencia de k en AIC, p_{WAIC} no tiene por qué coincidir con el número de parámetros escritos en el modelo.

LOO: evaluar cada dato como dato nuevo

En lugar de corregir el optimismo, podemos eliminar directamente la observación que queremos evaluar. **Para cada i :**

$$p(\theta \mid y_{-i})$$

es la distribución a posteriori obtenida sin utilizar y_i .

Entonces:

$$\widehat{\text{ELPD}}_{\text{LOO}} = \sum_{i=1}^N \log \left[\frac{1}{S} \sum_{s=1}^S p(y_i \mid \theta_{-i}^{(s)}) \right]$$

donde $\theta_{-i}^{(s)}$ son muestras de

$$p(\theta \mid y_{-i}).$$

¿Qué tan bien predice y_i un modelo que nunca vio y_i ?

Esto es LOO-CV...

El problema computacional de LOO

Si implementáramos LOO literalmente:

$$N \text{ observaciones} \Rightarrow N \text{ ajustes bayesianos}$$

Esto puede ser extremadamente costoso.

Pero ya tenemos un ajuste completo:

$$p(\theta \mid y)$$

¿Podemos reutilizar las muestras posteriores?

Sí, mediante muestreo de importancia

La idea es utilizar las muestras de una distribución que conocemos para aproximar otra distribución que sería costosa de obtener directamente.

Muestreo de importancia

Supongamos que queremos estudiar una distribución objetivo f , pero generamos muestras desde otra distribución g :

$$x^{(s)} \sim g.$$

Asignamos a cada muestra un peso:

$$w^{(s)} = \frac{f(x^{(s)})}{g(x^{(s)})}$$

Las muestras que son más representativas de f reciben mayor peso.

muestras de g $\xrightarrow{\text{pesos}}$ aproximación de f

El método funciona mejor cuando g cubre adecuadamente las regiones relevantes de f . Si algunos pesos son extremadamente grandes, las estimaciones pueden volverse inestables.

De importance sampling a LOO

En LOO queremos aproximar:

$$p(\theta \mid y_{-i})$$

utilizando muestras obtenidas de:

$$p(\theta \mid y).$$

El peso correspondiente es:

$$w_i^{(s)} = \frac{p(\theta^{(s)} \mid y_{-i})}{p(\theta^{(s)} \mid y)}.$$

Utilizando Bayes:

$$p(\theta \mid y) \propto p(\theta) \prod_{j=1}^N p(y_j \mid \theta)$$

$$p(\theta \mid y_{-i}) \propto p(\theta) \prod_{j \neq i} p(y_j \mid \theta)$$

Por lo tanto, al tomar el cociente:

$$w_i^{(s)} \propto \frac{1}{p(y_i \mid \theta^{(s)})}$$

PSIS-LOO: estabilizar los pesos

El muestreo de importancia puede producir pesos extremadamente grandes. Esto ocurre especialmente cuando una observación tiene mucha influencia sobre el ajuste, por lo que pueden dar valores diferentes

$$p(\theta \mid y_{-i}) \quad \text{y} \quad p(\theta \mid y)$$

Una solución es suavizar los pesos extremos mediante una distribución de Pareto:

Pareto-Smooth Importance Sampling

Combinado con LOO:

PSIS-LOO-CV

Posterior $\longrightarrow$ Importance Sampling $\longrightarrow$ Suavizado de pesos $\longrightarrow$ PSIS-LOO

En la práctica, habitualmente hablamos simplemente de **LOO**.

Ambos buscan estimar el desempeño predictivo **fuera de la muestra**.

WAIC

- ▶ Utiliza la distribución posterior.
- ▶ Corrige el optimismo mediante una penalización.
- ▶ Estima una complejidad efectiva.
- ▶ Es asintóticamente equivalente a LOO bajo ciertas condiciones.

LOO

- ▶ Imita validación cruzada.
- ▶ Evalúa cada dato fuera de la muestra.
- ▶ Puede calcularse eficientemente mediante PSIS.
- ▶ Proporciona diagnóstico mediante Pareto- k .

Cuando podemos elegir, suele ser preferible **LOO**, porque además de estimar el desempeño predictivo proporciona información diagnóstica sobre la calidad de la aproximación.

Diagnóstico Pareto- k

LOO estima un valor k_i para cada observación.

El parámetro k describe el comportamiento de la cola de los pesos de importancia y permite detectar aproximaciones problemáticas.

Como referencia práctica, a modo de ejemplo:

Valor de k	Interpretación
$k < 0.7$	Aproximación generalmente adecuada
$0.7 \leq k < 1$	Conviene revisar la observación
$k \geq 1$	Aproximación particularmente problemática

No son pruebas automáticas de que un modelo sea correcto o incorrecto. El umbral depende también de la cantidad de muestras posteriores.

Una observación con k alto puede ser:

- ▶ un dato problemático;
- ▶ un dato correcto pero particularmente influyente;
- ▶ señal de que el modelo no representa adecuadamente alguna característica de los datos.

LOO-PIT: ¿cómo predice el modelo cada observación?

LOO también puede utilizarse para evaluar un único modelo.

Para cada observación:

$$P(\tilde{y}_i \leq y_i \mid y_{-i})$$

donde $\tilde{y}_i$ representa un nuevo dato generado por la distribución predictiva.

La pregunta es:

*¿Qué tan compatible es y_i con la predicción
de un modelo que no utilizó y_i ?*

El gráfico **LOO-PIT** permite detectar problemas en la distribución predictiva, por ejemplo:

- ▶ falta de dispersión;
- ▶ exceso de dispersión;
- ▶ dificultades en determinadas regiones de los datos.

¿Y qué hacemos con DIC y BIC?

No todos los criterios responden exactamente la misma pregunta.

Criterio	Idea principal
AIC	Predicción + penalización por parámetros
BIC	Selección del modelo generador bajo ciertos supuestos
DIC	Criterio basado en deviance y complejidad efectiva
WAIC	Predicción bayesiana + complejidad efectiva
LOO	Predicción fuera de muestra mediante leave-one-out

En un análisis bayesiano

WAIC y, especialmente, LOO suelen ser preferibles para comparar modelos desde una perspectiva predictiva.

BIC merece una distinción importante:

“Bayesian” en el nombre $\neq$ “plenamente bayesiano”

BIC se basa en una aproximación que utiliza estimaciones puntuales y tiene una motivación diferente a los criterios predictivos.