

Modelos Jerárquicos

Eel II 2026

Clase 4 - 18/8/26

- ▶ Es común que los datos tengan una estructura jerárquica o en niveles.
- ▶ Ejemplos:
 - ▶ Rendimiento deportivo: corredores en distintos años.
 - ▶ Datos de salud: pacientes en diferentes hospitales.
 - ▶ Educación: estudiantes en escuelas, ciudades, provincias.
- ▶ Esta estructura se denomina **agrupamiento natural**.

► Opciones habituales:

1. Agrupar todos los datos en uno solo.
2. Analizar cada grupo por separado.

► Riesgos:

- Agrupar: se gana precisión pero se pierden diferencias (*ejemplo: paradoja de Simpson*).
- Separar: se capturan particularidades, pero con menor precisión y riesgo de sobreajuste.


- ▶ Pregunta: ¿Podemos construir un modelo que use información compartida entre grupos?
- ▶ Respuesta: Sí, los **modelos jerárquicos**.
- ▶ Otros nombres:
 - ▶ Modelos multinivel
 - ▶ Modelos de efectos mixtos
 - ▶ Modelos de efectos aleatorios
 - ▶ Modelos anidados
- ▶ Idea clave: usar **hiper-priors** para vincular grupos a una población común.

El introducir hiper-priors induce una distribución a posteriori donde las estimaciones de cada grupo estarán parcialmente agrupadas, es decir en algún punto entre el modelo agrupado y el modelo no agrupado. Para generar intuición sobre este punto, veamos el siguiente gráfico:

Nivel global
(media general)

No hay
parámetro global


Nivel
curso
(media
del curso)



Cada media se estima solo con los datos
de su propio curso.

Menos agrupamiento
(más variabilidad entre cursos)


Media global
(desconocida)



Cada media se estima usando sus datos,
pero "tirada" hacia la media global.
→ Agrupamiento parcial.

Agrupamiento parcial
(balance entre información propia y del conjunto)

Media global
(única)



No hay medias por curso: todos los datos
se combinan en una sola estimación.

Más agrupamiento
(menos variabilidad entre cursos)

Volvamos a nuestro ejemplo: 6 cursos

- ▶ Tenemos 6 cursos de escuelas, con diferentes cantidades de estudiantes:
 1. curso 1: 5 estudiantes
 2. curso 2: 8 estudiantes
 3. curso 3: 15 estudiantes
 4. curso 4: 30 estudiantes
 5. curso 5: 50 estudiantes
 6. curso 6: 80 estudiantes
- ▶ Cada curso tiene su propia media de rendimiento.
- ▶ Pero los cursos pertenecen a una misma población educativa.
- ▶ **Pregunta:** ¿cuánta información debería compartir cada curso con los demás?

Tres formas de tratar los cursos

Modelo no agrupado

Cada curso se analiza por separado. No se comparte información entre cursos.

$$\mu_1, \mu_2, \dots, \mu_6$$

Modelo agrupado

Todos los estudiantes se consideran parte de una única población. Todos los cursos comparten la misma media.

$$\mu_1 = \mu_2 = \dots = \mu_6 = \mu$$

Modelo jerárquico

Cada curso tiene su propia media, pero las medias están relacionadas:

$$\mu_j \sim p(\mu \mid \text{parámetros globales})$$

¿Qué hace diferente al modelo jerárquico?

Cada curso tiene su propia información



pero también recibe información del conjunto



agrupamiento parcial

- ▶ No obligamos a que todos los cursos sean iguales.
- ▶ Tampoco suponemos que sean completamente independientes.
- ▶ Permitimos que los datos determinen cuánto se parecen entre sí.

¿Qué es la contracción?

En un modelo jerárquico, las estimaciones de los grupos tienden a acercarse a la media global.

estimación del grupo $\leftarrow$ información propia + información global

- ▶ Este fenómeno se conoce como **contracción** (*shrinkage*).
- ▶ Las estimaciones extremas tienden a acercarse hacia la media global.
- ▶ La cantidad de contracción **no es igual para todos los grupos**.

¿Todos los grupos se contraen por igual?

No. La cantidad de contracción depende de la información disponible.

▶ **Muchos datos y poca incertidumbre:**

- ▶ la estimación propia es confiable;
- ▶ hay poca contracción.

▶ **Pocos datos y mucha incertidumbre:**

- ▶ la estimación propia es menos confiable;
- ▶ hay mayor contracción hacia la media global.

Idea intuitiva

El modelo jerárquico no “obliga” a los grupos a parecerse. **Los acerca más cuando los datos de ese grupo son poco informativos.**

- ▶ Recordemos los tamaños de muestra:

5, 8, 15, 30, 50, 80

- ▶ El curso con $n = 5$ tiene mucha más incertidumbre sobre su media que el curso con $n = 80$.
- ▶ Por lo tanto, esperamos:
 - ▶ mayor contracción para los cursos pequeños;
 - ▶ menor contracción para los cursos grandes.

poca información propia $\implies$ mayor peso de la información global

Una pregunta previa: ¿podemos considerar similares a los grupos?

Supongamos que tenemos varios cursos de una misma población educativa.

- ▶ ¿Qué diferencia al curso 1 del curso 2?
- ▶ ¿El hecho de llamarlos “curso 1” y “curso 2” contiene información?
- ▶ ¿Cambiarían nuestras conclusiones si intercambiáramos sus etiquetas?

Idea

Si no tenemos información que permita distinguirlos sistemáticamente, podemos considerar a los grupos **intercambiables**.

¿Qué significa intercambiabilidad?

Una colección de variables aleatorias es **intercambiable** si su distribución conjunta no cambia al reordenarlas.

$$p(X_1, \dots, X_n) = p(X_{\pi(1)}, \dots, X_{\pi(n)})$$

para cualquier permutación π .

En palabras

El orden o la etiqueta de las observaciones no aporta información relevante sobre su distribución conjunta.

Importante: intercambiabilidad no significa que las variables sean independientes.

Un ejemplo sencillo de intercambiabilidad

Supongamos que observamos tres personas elegidas de una misma población.

$$X_1, \quad X_2, \quad X_3$$

donde X_i representa la altura de la persona i .

Si no tenemos ninguna información adicional que distinga a las personas, esperamos que:

$$p(X_1, X_2, X_3) = p(X_3, X_1, X_2)$$

Interpretación

Cambiar las etiquetas “persona 1”, “persona 2” y “persona 3” no debería cambiar nuestro modelo probabilístico.

Intercambiabilidad no es independencia

Las variables pueden ser intercambiables sin ser independientes.

- ▶ **Independencia:** conocer X_1 no cambia nuestra distribución para X_2 .
- ▶ **Intercambiabilidad:** el orden de $X_1, X_2, \dots$ no cambia la distribución conjunta.

$$\text{iid} \implies \text{intercambiable}$$

pero

$$\text{intercambiable} \not\implies \text{iid}$$

¿Qué tiene que ver esto con un modelo jerárquico?

Supongamos que tenemos varios grupos: $\theta_1, \theta_2, \dots, \theta_J$ y creemos que pertenecen a una misma población.

Entonces podemos pensar que:

$$\theta_j \sim p(\theta \mid \psi)$$

donde ψ describe las características de la población común.

población común	$\longrightarrow$	$\theta_1, \theta_2, \dots, \theta_J$
-----------------	-------------------	---------------------------------------

- ▶ Los grupos tienen parámetros propios.
- ▶ Pero esos parámetros provienen de una distribución común.
- ▶ Por eso los grupos comparten información.

Supongamos que no tenemos información adicional que distinga sistemáticamente a los 6 cursos.

Entonces podemos considerar intercambiables sus parámetros:

$$\mu_1, \mu_2, \dots, \mu_6$$

Esto significa que el modelo no asigna un tratamiento especial al curso 1, al curso 2, etc.

Podemos representarlo mediante: $\mu_j \sim \mathcal{N}(\mu, \sigma_\mu)$ para $j = 1, \dots, 6$.

Idea clave

Los cursos no tienen que ser iguales. Son considerados **similares a priori** porque pertenecen a una misma población.

Para cada curso:

$$y_{ij} \mid \mu_j, \sigma \sim \mathcal{N}(\mu_j, \sigma)$$

Las medias de los cursos:

$$\mu_j \mid \mu, \sigma_\mu \sim \mathcal{N}(\mu, \sigma_\mu)$$

Y los parámetros globales reciben sus propios priors:

$$\mu \sim p(\mu), \quad \sigma_\mu \sim p(\sigma_\mu)$$

datos $\rightarrow$ parámetros de grupo $\rightarrow$ parámetros globales

¿Qué hacen los hiperparámetros?

En $\mu_j \sim \mathcal{N}(\mu, \sigma_\mu)$ tenemos:

- ▶ μ : ubicación de la población de cursos.
- ▶ σ_μ : cuánto pueden diferir los cursos entre sí.

Si σ_μ es pequeño

Las medias de los cursos tienden a estar cerca de μ .
 $\implies$ más agrupamiento

Si σ_μ es grande

Las medias de los cursos pueden diferir más.
 $\implies$ menos agrupamiento

¿Por qué aparece la contracción?

La distribución jerárquica representada por:

$$\mu_j \sim \mathcal{N}(\mu, \sigma_\mu)$$

combina dos fuentes de información:

1. la información específica del curso j ;
2. la información compartida por todos los cursos.

Por eso, la estimación posterior de μ_j puede alejarse de la media global cuando sus datos son informativos, pero acercarse a ella cuando existe mayor incertidumbre.

contracción = combinación de información local y global

Para profundizar

El Teorema de De Finetti establece una conexión profunda entre **intercambiabilidad** y **modelos probabilísticos con parámetros latentes**.

La idea general es que una secuencia intercambiable puede interpretarse como condicionalmente independiente dado un parámetro común.

intercambiabilidad $\implies$ estructura probabilística compartida

Esta conexión proporciona una fundamentación teórica para muchas construcciones jerárquicas bayesianas.

Supongamos que observamos los puntajes de 10 estudiantes en una misma evaluación:

$$y_1, \dots, y_{10}$$

Tenemos los puntajes de 9 estudiantes, pero desconocemos y_4 .

Pregunta

¿Qué podemos decir sobre el puntaje del estudiante 4?

y_1	y_2	y_3	y_5	y_6	y_7	y_8	y_9	y_{10}
72	81	68	75	79	64	83	71	77

Pregunta:

Si no sabemos nada más sobre el estudiante 4, ¿qué puntaje esperaríamos para y_4 ?

Supongamos que, por ahora, no tenemos información que permita distinguir a los estudiantes entre sí.

Si los consideramos intercambiables:

- ▶ ninguna posición tiene un tratamiento especial;
- ▶ cambiar las etiquetas de los estudiantes no cambia nuestro modelo;
- ▶ los demás puntajes nos proporcionan información sobre y_4 .

Con los 9 valores observados:

$$\bar{y}_{-4} \approx 74.44$$

Como primera aproximación:

$$y_4 \approx 74.44$$

¿Qué ocurre si tenemos información adicional?

Ahora descubrimos que los estudiantes pertenecen a **distintos cursos**.

Por ejemplo:

Estudiante	Curso
1, 2, 3, 4	<i>A</i>
5, 6, 7	<i>B</i>
8, 9, 10	<i>C</i>

Esta información nos permite distinguir grupos.

Nueva pregunta

¿Deberíamos seguir tratando a todos los estudiantes como si pertenecieran a una única población?

De la intercambiabilidad al modelo jerárquico

Ahora podemos permitir que cada curso tenga su propia media:

$$\mu_A, \quad \mu_B, \quad \mu_C$$

pero suponemos que los cursos pertenecen a una misma población educativa.

Por lo tanto:

$$\mu_j \sim p(\mu \mid \psi)$$

para cada curso j .

- ▶ Cada curso tiene su propio parámetro.
- ▶ Los parámetros de los cursos están relacionados.
- ▶ La información de un curso puede contribuir a aprender sobre los demás.

Intercambiabilidad dentro de la jerarquía

La información de grupo no elimina la intercambiabilidad.

Ahora podemos considerar intercambiables a los cursos **dentro de la población de cursos**:

$$\mu_1, \mu_2, \dots, \mu_J$$

Es decir, antes de observar los datos, no suponemos que el curso 1 sea sistemáticamente diferente del curso 2.

Pero permitimos que los datos indiquen diferencias entre ellos:

$$\mu_j \sim \mathcal{N}(\mu, \sigma_\mu)$$

Idea clave

Los cursos son diferentes, pero provienen de una **misma población de cursos**.

Tenemos grupos de datos



Creemos que pertenecen a una población común



Podemos considerar intercambiables a los grupos



Asignamos una distribución poblacional común



Modelo jerárquico



Agrupamiento parcial + contracción



Los hiperparámetros determinan cuánto pueden diferir los grupos