Ejercicio 1:

Investigar sobre la Paradoja de Simpson y comentar la relación que tiene con los modelos jerárquicos vistos en clase.

1. ¿Qué es la Paradoja de Simpson?

La **Paradoja de Simpson** es un fenómeno estadístico en el cual una tendencia, asociación o correlación observada dentro de múltiples subgrupos **desaparece o se invierte completamente** cuando los datos se analizan de manera agregada (combinando todos los grupos en uno solo).

Ocurre principalmente debido a la presencia de una **variable confusora o de agrupamiento** que afecta tanto a la variable predictora como a la respuesta, distribuyéndose de forma desigual entre los grupos.

---

2. Ejemplo Intuitivo: Tratamientos Médicos

Supongamos la comparación entre dos tratamientos (A y B) para evaluar su tasa de éxito:

- **En casos leves:** El Tratamiento A tiene una tasa de éxito del 90%, mientras que el B alcanza el 80%.
- **En casos graves:** El Tratamiento A tiene una tasa de éxito del 50%, mientras que el B alcanza el 40%.
- **Datos combinados:** Al juntar todos los pacientes, el Tratamiento B parece tener una tasa de éxito global superior al A.

Explicación: El tratamiento A se administró principalmente a pacientes en estado grave (con baja probabilidad basal de supervivencia), mientras que el tratamiento B se asignó mayoritariamente a pacientes leves. La severidad del caso actúa como la variable confusora que distorsiona la conclusión agregada.

---

3. Relación con los Modelos Jerárquicos

La Paradoja de Simpson es la consecuencia directa de **ignorar la estructura anidada o de agrupamiento de los datos**. Los modelos jerárquicos permiten abordar y resolver este problema al formalizar las distintas formas de agregar información:

A. Modelo con Agrupamiento Total (*Complete Pooling*)

- Asume un único parámetro global e ignora por completo la existencia de grupos.
- **Problema:** Es el más vulnerable a la Paradoja de Simpson, ya que confunde las diferencias entre grupos con el efecto real de la variable de interés.

B. Modelo sin Agrupamiento (*No Pooling*)

- Estima parámetros completamente independientes para cada grupo.
- **Problema:** Aunque evita la inversión de tendencias, genera estimaciones inestables y con alta varianza en grupos con tamaños de muestra pequeños, impidiendo extrapolar a la población general.

C. Modelo Jerárquico (*Partial Pooling*)

- Asume que los parámetros de cada grupo provienen de una distribución poblacional común gobernada por hiperparámetros (μ, σ).
- **Resolución de la paradoja:** Permite descomponer simultáneamente:
  - **Efecto dentro del grupo (*within-group*):** Estima la relación real de las variables dentro de cada grupo específico.
  - **Efecto entre grupos (*between-group*):** Modela las diferencias estructurales y basales entre los distintos grupos.
- Al modelar pendientes e interceptos que varían por grupo mediante contracción hacia la media (*shrinkage*), el modelo jerárquico controla el efecto de la variable de agrupamiento y previene el sesgo de agregación.

Ejercicio 2: Bayes Jerárquico

Escribir el teorema de Bayes para un modelo jerárquico.

En un modelo jerárquico se definen los siguientes componentes:

- $y = (y_1, y_2, \ldots, y_J)$: Datos observados organizados en J grupos.
- $\theta = (\theta_1, \theta_2, \ldots, \theta_J)$: Parámetros específicos de cada grupo (nivel 2).
- $\psi = (\mu, \sigma, \ldots)$: Hiperparámetros que gobiernan la distribución poblacional común de los grupos (nivel 3).

Teorema de Bayes para la Distribución Posterior Conjunta

La distribución a posteriori conjunta de los parámetros específicos de grupo θ y los hiperparámetros ψ dado los datos observados y se formula como:

$$p(\theta, \psi \mid y) = \frac{p(y \mid \theta, \psi)\, p(\theta, \psi)}{p(y)}$$

Aplicando la regla de la cadena para factorizar la conjunta $p(\theta, \psi) = p(\theta \mid \psi)\, p(\psi)$ y considerando que los datos y dependen de ψ únicamente a través de θ (es decir, $p(y \mid \theta, \psi) = p(y \mid \theta)$):

$$p(\theta, \psi \mid y) = \frac{p(y \mid \theta)\, p(\theta \mid \psi)\, p(\psi)}{\iint p(y \mid \theta)\, p(\theta \mid \psi)\, p(\psi)\, d\theta\, d\psi}$$

En forma proporcional (omitiendo la evidencia o constante de normalización):

$$p(\theta, \psi \mid y) \propto p(y \mid \theta)\, p(\theta \mid \psi)\, p(\psi)$$

Descomposición por Niveles de Independencia Condicional

Bajo el supuesto de que las observaciones dentro de cada grupo son condicionalmente independientes dado su parámetro θ_j, y que los parámetros θ_j son intercambiables condicionados a ψ:

$$p(\theta, \psi \mid y) \propto \left[\prod_{j=1}^{J} p(y_j \mid \theta_j)\, p(\theta_j \mid \psi)\right] p(\psi)$$

Donde cada término corresponde a:

- $p(y_j \mid \theta_j)$: **Verosimilitud (Likelihood) - Nivel 1**, probabilidad de los datos del grupo j dado su parámetro θ_j.
- $p(\theta_j \mid \psi)$: **Prior de grupo - Nivel 2**, distribución poblacional común de los parámetros de cada grupo condicionada a los hiperparámetros.
- $p(\psi)$: **Hiperprior - Nivel 3**, distribución a priori de los parámetros globales de la población.

Distribuciones Marginales Posteriores

- **Posterior Marginal de los Hiperparámetros (ψ):** Integrando respecto a los parámetros de grupo θ:

$$p(\psi \mid y) \propto p(\psi) \int p(y \mid \theta)\, p(\theta \mid \psi)\, d\theta = p(\psi)\, p(y \mid \psi)$$

- **Posterior Marginal de los Parámetros de Grupo (θ):** Integrando respecto a los hiperparámetros ψ:

$$p(\theta \mid y) = \int p(\theta, \psi \mid y)\, d\psi = \int p(\theta \mid \psi, y)\, p(\psi \mid y)\, d\psi$$

Ejercicio 3:

Si tenemos los datos de atenciones mensuales de diferentes vacunatorios de la provincia. El objetivo es construir un modelo jerárquico para predecir las vacunaciones futuras y entender la variabilidad entre vacunatorios. Modelizar con un breve esquema de como podría ser un modelo de ese tipo. ¿Es jerárquico o no jerárquico el mejor planteo?

El **enfoque jerárquico (pooling parcial) es el mejor planteo**, debido a las siguientes razones:

1. **Heterogeneidad de tamaños muestrales:** Existen vacunatorios grandes (hospitales centrales) con alto volumen de atención y vacunatorios pequeños (salitas rurales) con pocas observaciones. Un modelo independiente (*no pooling*) sobreajustaría en los centros chicos, mientras que un modelo global (*complete pooling*) ignoraría las diferencias estructurales de cada centro.

2. **Compartición de información (*Shrinkage*):** Los centros con pocos registros o meses atípicos se benefician de la información poblacional global (μ, σ), estabilizando las predicciones futuras.
3. **Cuantificación de la variabilidad (σ):** El hiperparámetro de dispersión permite responder directamente al objetivo de medir la heterogeneidad entre vacunatorios.
4. **Predicción para nuevos vacunatorios:** Permite hacer predicciones para un centro de salud nuevo del que no se tienen datos históricos, muestreando directamente desde la distribución poblacional $\mathrm{N}(\mu, \sigma)$.

Esquema Matemático del Modelo (Regresión Poisson/Binomial Negativa)

Dado que las atenciones mensuales son **datos de conteo** ($y_{i,t} \in \mathrm{N}_0$ para el vacunatorio i en el mes t):

Nivel 1: Datos observados (Likelihood)

$$y_{i,t} \sim \mathrm{Poisson}(\lambda_{i,t}) \quad \text{o} \quad y_{i,t} \sim \mathrm{NegativeBinomial}(\lambda_{i,t}, \alpha)$$

Como la tasa $\lambda_{i,t}$ debe ser estrictamente positiva, se utiliza la función de enlace logarítmica (*log-link*):

$$\log(\lambda_{i,t}) = \theta_i + \beta \cdot t$$

(donde t puede representar una tendencia temporal o estacionalidad y θ_i es el nivel basal del vacunatorio i)

Nivel 2: Parámetros por Vacunatorio (Efectos de grupo)

$$\theta_i \sim \mathrm{N}(\mu, \sigma)$$

- θ_i: Tasa basal esperada de atenciones del vacunatorio i en escala logarítmica.

Nivel 3: Población de Vacunatorios (Hiperpriors)

$$\mu \sim \mathrm{N}(0, 2)$$

$$\sigma \sim \mathrm{HalfNormal}(1)$$

$$\beta \sim \mathrm{N}(0, 1)$$

- μ: Media global poblacional de atenciones en escala log.
- σ: Variabilidad o heterogeneidad entre los distintos vacunatorios de la provincia.

---

3. Diagrama Estructural de Niveles

```
              (μ, σ, β) ~ p(ψ)                Nivel 3: Hiperpriors
(Parámetros provinciales)
                        │
                        ▼
            θ_i ~ Normal(μ, σ)                Nivel 2: Efecto basal de
```

```
cada vacunatorio i
                        |
                        ▼
      y_it ~ Poisson(exp(θ_i + β·t))          Nivel 1: Atenciones
mensuales observadas
```

Ejercicio 4:

> Agregar bloque entrecomillado

Una empresa agrícola desea evaluar la calidad de un nuevo tratamiento para semillas. Para ello, se sembraron semillas tratadas en distintos invernaderos. En cada uno se registró si cada semilla logró germinar correctamente.

Cada observación se codifica como:

1: la semilla germinó correctamente.

0: la semilla no germinó.

Los datos se encuentran agrupados por invernadero. Aunque cada invernadero puede presentar condiciones particulares de temperatura, humedad o iluminación, se supone que todos pertenecen a una misma población y, por lo tanto, resulta razonable modelarlos mediante un enfoque jerárquico.

Para este ejercicio se utilizarán datos sintéticos correspondientes a cuatro invernaderos.

In [ ]:
```python
import numpy as np

# Cantidad de semillas evaluadas por invernadero
N = [20, 30, 25, 40]

# Cantidad de semillas germinadas
G = [15, 18, 11, 34]

group_idx = np.repeat(np.arange(len(N)), N)

data = []

for i in range(len(N)):
    data.extend(np.repeat([1, 0], [G[i], N[i]-G[i]]))

data = np.array(data)
```

Actividades:

a) Plantee un modelo jerárquico bayesiano para estimar la probabilidad de germinación de cada invernadero. Describa el significado de cada uno de los parámetros e indique qué distribución asignaría a cada nivel del modelo.

b) Implemente el modelo utilizando PyMC y obtenga muestras de la distribución posterior.

c) Obtenga un resumen posterior de las probabilidades de germinación de cada invernadero y de los hiperparámetros del modelo. ¿Qué información aporta cada uno de ellos?

d) Repita el análisis modificando únicamente los datos del último invernadero para obtener los siguientes escenarios

In [ ]:
```
# Escenario A
G = [15, 18, 11, 34]
```

In [ ]:
```
# Escenario B
G = [15, 18, 11, 8]
```

In [ ]:
```
# Escenario C
G = [15, 18, 11, 20]
```

Ejercicio 5: (opcional)

Recordando el modelo estudiado en clase sobre la supervivencia de los renacuajos: considere que ha ajustado el modelo jerárquico para estimar la probabilidad de supervivencia de los renacuajos en los distintos tanques y que ya dispone de muestras de la distribución posterior obtenidas mediante MCMC.

A partir de dichas muestras:

a) ¿Cómo estimaría la media posterior de la probabilidad de supervivencia de un tanque?

b) ¿Cómo calcularía un intervalo de máxima densidad (HDI) del 94% para esa probabilidad?

c) ¿Cómo estimaría la probabilidad de que la supervivencia en un determinado tanque sea superior al 60% utilizando únicamente las muestras obtenidas?

No es necesario obtener expresiones analíticas; describa el procedimiento y, si lo considera conveniente, impleméntelo en Python.

Ejercicio 6: (ejercicio guiado)

Modelo jerárquico multinivel para jugadores de fútbol

Los modelos jerárquicos pueden extenderse naturalmente a problemas con más de un nivel de agrupamiento. En este ejercicio analizaremos un ejemplo con tres niveles.

Se dispone de estadísticas de jugadores profesionales pertenecientes a cinco ligas europeas (Premier League, Ligue 1, Bundesliga, Serie A y La Liga) durante las temporadas 2017–2020.

Para cada jugador se registró:

la posición en la que juega (arquero, defensor, mediocampista o delantero), la cantidad total de tiros realizados, la cantidad de goles convertidos.

Nuestro objetivo será estimar la probabilidad de convertir un gol dado un tiro, es decir, la tasa de éxito de cada jugador.

Supondremos que:

los jugadores pertenecientes a una misma posición comparten características similares; las distintas posiciones pertenecen, a su vez, a una población general de futbolistas profesionales.

En consecuencia, la estructura jerárquica del problema puede representarse mediante tres niveles:

Nivel 1: jugadores; Nivel 2: posiciones; Nivel 3: población general de futbolistas.

Los datos pueden cargarse mediante:

In [ ]:
```
futbol = pd.read_csv("datos/futbol.csv", dtype={"posición":"category"})

pos_idx = futbol.posición.cat.codes.values
pos_codes = futbol.posición.cat.categories

coords = {"pos": pos_codes}
```

a) Identifique los distintos niveles jerárquicos presentes en este problema e indique cuáles son:

i) las observaciones;

ii) los parámetros asociados a cada jugador;

iii) los parámetros asociados a cada posición;

iv) los hiperparámetros globales.

b) Escriba el modelo jerárquico utilizando notación estadística. Identifique claramente:

- la distribución de verosimilitud;
- las distribuciones a priori correspondientes a cada nivel de la jerarquía;
- los hiperparámetros del modelo.

c) Implemente el modelo utilizando PyMC.

Utilice como guía la siguiente estructura:

In [ ]:
```
with pm.Model(coords=coords):

    ...
```

```
idata = pm.sample(...)
```

d) Genere el grafo probabilístico del modelo.

A partir del mismo, identifique:

- cuáles son las variables observadas;
- cuáles son los parámetros por jugador;
- cuáles corresponden a cada posición;
- cuáles representan la población general.

e) Obtenga un resumen posterior de los parámetros globales y de los parámetros asociados a cada posición.

¿Qué interpretación puede darse a cada uno de ellos?

f) Grafique la distribución posterior de:

i) la media global μ;

ii) la media correspondiente a los delanteros (μ_p);

iii) la probabilidad de éxito (θ) de un jugador a elección.

Interprete los resultados obtenidos.

g) Construya un forest plot para los parámetros μ_p. A partir del gráfico:

- compare las distintas posiciones;
- identifique cuál presenta la mayor probabilidad media de convertir goles;
- determine cuál presenta mayor incertidumbre y proponga una explicación.

h) Explique por qué este problema requiere un modelo con tres niveles jerárquicos y cuáles serían las limitaciones de modelar cada jugador de manera independiente.

i) (opcional)

Suponga que un nuevo delantero profesional realizó únicamente 8 tiros y convirtió 3 goles.

Sin modificar el código, responda conceptualmente:

i) ¿Esperaría que el modelo jerárquico estime exactamente una tasa de éxito de 3/8?

ii) ¿Hacia qué valor tendería a desplazarse esa estimación?

iii) ¿Qué papel juegan los parámetros de la posición y de la población general en dicha estimación?

Justifique su respuesta utilizando el concepto de contracción (shrinkage).