Ejercicio 1 — Del problema a un modelo

Una empresa quiere estimar la proporción de semillas que germinan bajo determinadas condiciones. Se observan 20 semillas y 13 germinan.

Se propone el siguiente modelo:

$$G \sim Binomial(20, p)$$

$$p \sim Beta(2, 2)$$

a) Identifiquen en este problema:

i. los datos observados;

ii. el parámetro de interés;

iii. la distribución de los datos;

iv. la distribución a priori;

v. el objetivo de la inferencia.

b) Antes de observar los datos, generen muestras de la distribución predictiva a priori. Para ello, simulá valores de p provenientes del prior y, para cada uno, simulá un valor de G.

c) Realicen un gráfico de la *distribución predictiva a priori* de G.

d) ¿El prior elegido permite observar resultados compatibles con una cantidad de germinaciones entre 0 y 20? ¿Te parece razonable para este problema? Utilicen el gráfico para repsonder.

e) Luego incorporen el dato observado $G = 13$ y obtené la distribución a posteriori de p. Comparar el prior y el posterior.

Ejercicio 2 — ¿El modelo puede reproducir los datos?

Ahora supongamos que tenemos los siguientes datos correspondientes a 30 observaciones:

In [ ]:
```
y = [4.2, 4.8, 5.1, 4.7, 5.3, 4.9, 5.0, 4.6, 5.2, 4.8,
     5.1, 4.9, 5.4, 4.7, 5.0, 5.2, 4.8, 5.1, 4.9, 5.3,
     4.7, 5.0, 5.2, 4.8, 5.1, 4.9, 5.4, 4.6, 5.0, 5.2]
```

Se ajusta el modelo:

$$y_i \sim N(\mu, \sigma^2)$$

con

$$\mu \sim N(0, 10^2)$$

$$\sigma \sim HalfNormal(10^2)$$

a) Ajusten el modelo mediante MCMC.

b) Realicen una prueba predictiva a posteriori utilizando `az.plot_ppc`.

c) Comparen visualmente los datos observados con los datos simulados a partir del posterior.

d)¿El modelo genera datos parecidos a los observados?

e) Elijan un estadístico sencillo, por ejemplo la media, y calculá su distribución predictiva.

Comparen la media observada con las medias obtenidas mediante las simulaciones predictivas.

f) Expliquen con sus palabras qué significa que un modelo "pueda reproducir los datos observados".

g) (opcional) Modificar el modelo suponiendo:

$$y_i \sim N(\mu, 0.5^2)$$

es decir, utilizando una desviación estándar fija.

Repitan el chequeo predictivo y comparen ambos modelos.

Ejercicio 3 — ¿Más parámetros significa un modelo mejor?

Se generan datos a partir de:

$$y_i = 2 + 0.8x_i + \epsilon_i,$$

$$\epsilon_i \sim N(0, 1)$$

para $x_i \in [0, 10]$.

Se proponen tres modelos:

Modelo A: $y_i \sim N(\alpha, \sigma^2)$

Modelo B: $y_i \sim N(\alpha + \beta x_i, \sigma^2)$

Modelo C: $y_i \sim N(\alpha + \beta_1 x_i + \beta_2 {x_i}^2 + \beta_3 {x_i}^3 + \beta_4 {x_i}^4 + \beta_5 {x_i}^5, \sigma^2)$a) Ajusten los tres modelos.

b) Grafiquen los datos junto con algunas predicciones de cada modelo.

c) Comparen visualmente el ajuste de los tres modelos.

d) Indiquen cuál de los modelos presenta:

- subajuste;
- un equilibrio razonable entre complejidad y ajuste;
- riesgo de sobreajuste.

e) ¿Cuál elegirían si solamente miraran qué tan bien se ajusta a los datos utilizados para entrenar el modelo?

f) ¿Por qué esa estrategia puede ser problemática?

g) Dividan los datos en un conjunto de entrenamiento y uno de prueba. Comparen el desempeño predictivo de los tres modelos sobre los datos que no utilizaron para ajustar los parámetros.

Ejercicio 4 — Comparando modelos: AIC, WAIC y LOO

Ahora retomamos los modelos del ejercicio anterior.

Para cada modelo, calculen:

i. AIC;

ii. WAIC;

iii. LOO.

Pueden utilizar las funciones correspondientes de ArviZ para los criterios bayesianos.

a) Construyan una tabla que contenga, para cada modelo:

(Modelo - Nº - parámetros - AIC - WAIC - LOO)

b) Para cada criterio, indicar cuál sería el modelo seleccionado.

c) Explicar porqué es necesario que los criterios de información busquen equilibrar la "calidad del ajuste" y la "complejidad del modelo".

d) Comparen sus resultados con los obtenidos mediante el conjunto de prueba del ejercicio anterior.

e) Utilizar `az.compare` para comparar los modelos mediante LOO.

f) ¿Los diferentes métodos conducen a conclusiones similares?

g) En no más de 4 o 5 líneas, explicar la diferencia fundamental que existe entre evaluar el ajuste sobre los datos utilizados para estimar el modelo y evaluar su capacidad predictiva.