Actividades de repaso – Bloque 1 (Resuelto)

Ejercicio 1: En un modelo bayesiano, la distribución posterior:

a) Se obtiene combinando la información previa con la información proporcionada por los datos.

b) Depende únicamente de los datos observados.

c) Es siempre igual a la distribución a priori cuando se dispone de pocos datos.

Resolución: La opción correcta es es la a). La idea fundamental de la inferencia bayesiana se expresa mediante el teorema de Bayes:

$$p(\theta \mid y) = \frac{p(y \mid \theta)\, p(\theta)}{p(y)}.$$

Como el denominador no depende de θ, suele escribirse:

$$\boxed{p(\theta \mid y) \propto p(y \mid \theta)\, p(\theta)}$$

donde:

- $p(\theta)$ es la distribución **a priori** o *prior*;
- $p(y \mid \theta)$ es la **verosimilitud**;
- $p(\theta \mid y)$ es la distribución **posterior**.

Por lo tanto, la distribución posterior combina la información que teníamos antes de observar los datos con la información aportada por los datos.

La opción b) es falsa porque la posterior no depende únicamente de los datos. También depende del prior:

$$p(\theta \mid y) \propto p(y \mid \theta)\, p(\theta).$$

La opción c) también es falsa. Cuando tenemos pocos datos, el prior puede tener una influencia importante sobre la posterior, pero esto no significa que la posterior sea siempre igual al prior. De hecho, incluso con pocos datos, los datos aportan información y pueden modificar la distribución previa.

Ejercicio 2: Se desea modelar la probabilidad p de éxito de un determinado procedimiento.

Antes de observar datos:

$$p \sim \text{Beta}(4, 6).$$

Luego se realizan 15 experimentos independientes y se observan 11 éxitos.

a) Escriba la distribución posterior de p.

b) Calcule la media posterior.

c) Compare conceptualmente la media del prior con la media posterior.

Resolución:

a) Tenemos un modelo Beta-Binomial. El prior es:

$$p \sim \text{Beta}(\alpha, \beta),$$

con: $\alpha = 4$, $\beta = 6$.

Los datos corresponden a $n = 15$ experimentos, de los cuales: $x = 11$ son éxitos. Por lo tanto, la cantidad de fracasos es: $n - x = 15 - 11 = 4$.

Para el modelo Beta-Binomial, la distribución posterior tiene la forma:

$$p \mid y \sim \text{Beta}\left(\alpha + x,\ \beta + n - x\right).$$

Reemplazando:

$$p \mid y \sim \text{Beta}\left(4 + 11,\ 6 + 4\right).$$

Entonces:

$$\boxed{p \mid y \sim \text{Beta}(15, 10)}$$

b) Si $p \sim \text{Beta}(\alpha, \beta)$, su media es:

$$E[p] = \frac{\alpha}{\alpha + \beta}.$$

Como la posterior es:

$$p \mid y \sim \text{Beta}(15, 10),$$

tenemos:

$$E[p \mid y] = \frac{15}{15 + 10} = \frac{15}{25} = 0{,}60.$$

c) La media del prior es:

$$E[p] = \frac{4}{4 + 6} = 0{,}40.$$

La media posterior es:

$$E[p \mid y] = 0{,}60.$$

Por lo tanto, la estimación se desplazó hacia valores mayores de p. Esto es coherente con los datos observados, ya que se observaron $\frac{11}{15} \approx 0{,}73$.

Los datos sugieren una probabilidad de éxito relativamente alta y, por lo tanto, empujan la distribución posterior hacia valores mayores.

Ejercicio 3: Se quiere modelar la proporción p de clientes que abandonan un servicio durante el primer mes.

No se conoce exactamente cuál es esa proporción, pero por experiencia se considera razonable pensar que suele ser relativamente baja, aunque podría variar entre empresas.

a) Proponga una distribución a priori para p.

b) Explique qué información está incorporando su elección.

c) ¿Consideraría que su prior es fuertemente informativo, débilmente informativo o no informativo? Justifique.

Resolución:

a) Como p representa una proporción, sabemos que: $0 < p < 1$. Una distribución natural para modelar una proporción es la distribución Beta. Por ejemplo, podemos proponer:

$$\boxed{p \sim \text{Beta}(2, 8)}$$

No existe una única respuesta correcta para este ejercicio. Lo importante es que la distribución elegida sea coherente con la información disponible y que podamos justificarla.

b) La media de una distribución Beta es:

$$E[p] = \frac{\alpha}{\alpha + \beta}.$$

Para nuestro prior:

$$E[p] = \frac{2}{2+8} = 0{,}20.$$

Por lo tanto, estamos expresando que, antes de observar los datos, consideramos razonable que la proporción de clientes que abandona el servicio se encuentre alrededor del 20 %.

Sin embargo, no estamos afirmando que: $p = 0{,}20$ con certeza. Estamos utilizando una distribución que asigna probabilidades a distintos valores posibles de p.

c) Podemos considerar este prior como **débilmente informativo**. Incorpora la información de que: ‘‘`la proporción suele ser relativamente baja`’’, pero no concentra toda la probabilidad alrededor de un único valor. Por lo tanto, permite que los datos tengan un papel importante en la actualización.

Ejercicio 4: Considere el siguiente código:

```
with modelo:
    posterior_pred = pm.sample_posterior_predictive(
    idata,
    var_names=["y_obs"]
)

    y_rep = posterior_pred.posterior_predictive["y_obs"].values
```

a) ¿Qué representan los valores almacenados en `y_rep`?

b) ¿Son nuevas simulaciones generadas directamente desde el prior?

c) Explique por qué estas simulaciones pueden utilizarse para evaluar si el modelo es capaz de reproducir características relevantes de los datos observados.

Resolución:

a) Los valores almacenados en `y_rep` representan réplicas simuladas de los datos. Estas réplicas se generan a partir de la **distribución predictiva posterior**. Conceptualmente:

$$\boxed{\tilde{y} \sim p(\tilde{y} \mid y)}$$

Es decir, una vez ajustado el modelo con los datos observados, generamos datos nuevos que podrían haber sido observados si el modelo fuera capaz de reproducir razonablemente el mecanismo que generó los datos.

¿Cómo se generan las réplicas? Supongamos que tenemos muestras posteriores:

$$\theta^{(1)}, \theta^{(2)}, \ldots, \theta^{(S)}$$

provenientes de $p(\theta \mid y)$. Para cada muestra posterior generamos datos:

$$\tilde{y}^{(s)} \sim p(y \mid \theta^{(s)}).$$

Por lo tanto:

$$\boxed{\theta^{(s)} \sim p(\theta \mid y) \quad \Longrightarrow \quad \tilde{y}^{(s)}(y \mid \theta^{(s)})}$$

Las observaciones simuladas $\tilde{y}^{(s)}$ constituyen las réplicas que encontramos en `y_rep`.

b) No, no provienen directamente del prior. El flujo conceptual es:

$$\boxed{\text{Datos observados} \longrightarrow \text{Distribución posterior} \longrightarrow \text{Datos simulados}}$$

Por eso hablamos de **distribución predictiva posterior**.

c) Tenemos los datos observados: y, y generamos muchas réplicas:

$$\tilde{y}^{(1)}, \tilde{y}^{(2)}, \ldots, \tilde{y}^{(S)}.$$

Podemos comparar características relevantes de los datos reales con las mismas características de los datos simulados. Por ejemplo:

- la media;
- la varianza;
- el máximo;
- el mínimo;
- una proporción;
- una cantidad de éxitos;
- la dispersión;
- otras características relevantes.

Si el modelo es razonable, esperamos que las réplicas simuladas puedan reproducir características importantes de los datos observados.

Ejercicio 5: Supongamos que, luego de ajustar un modelo bayesiano a unos datos y, generamos réplicas $\tilde{y}$ a partir de la distribución predictiva posterior.

Queremos comparar una característica de los datos observados con la misma característica en los datos simulados mediante un estadístico T.

El Bayesian p-value se define como:

$$\boxed{p_B = P\left(T(\tilde{y}) \leq T(y) \mid y\right)}$$

a) Explique qué representa $T(y)$.

b) ¿Qué representa $T(\tilde{y})$?

c) ¿De qué distribución provienen los datos simulados $\tilde{y}$?

a) $T(y)$ representa un **estadístico o característica de los datos observados**. Por ejemplo, podemos elegir como estadístico la media:

$$T(y) = \bar{y}.$$

En ese caso, primero tenemos los datos observados: $y = (y_1, \ldots, y_n)$ y calculamos:

$$T(y) = \bar{y} = \frac{1}{n} \sum_{i=1}^{n} y_i.$$

Es decir, $T(y)$ es el valor observado del estadístico elegido.

b) $\tilde{y}$ representa una réplica de los datos generada a partir de la distribución predictiva posterior. Sobre esa réplica calculamos exactamente el mismo estadístico: $T(\tilde{y})$. Por ejemplo, si: $T(y) = \bar{y}$, entonces: $T(\tilde{y}) = \overline{\tilde{y}}$.

c) Las réplicas $\tilde{y}$ provienen de la: `distribución predictiva posterior`, es decir: $\tilde{y} \sim p(\tilde{y} \mid y)$. No se generan directamente desde el prior.

Ejercicio 6: Para evaluar un modelo se calcula un Bayesian p-value utilizando una determinada característica T de los datos.

1. Indique cuál de las siguientes interpretaciones es más adecuada:

   - *Caso A:* $p_B \approx 0{,}50$

   a) El modelo es compatible con esa característica de los datos.

   b) La hipótesis nula tiene un 50 % de probabilidad de ser verdadera.

   c) Se acepta el modelo porque el p-value es mayor que 0,05.

   - *Caso B:* $p_B \approx 0{,}02$

   ¿Qué indica este resultado sobre la posición del estadístico observado dentro de la distribución de los estadísticos simulados?

   - *Caso C:* $p_B \approx 0{,}97$

   ¿Qué indica este resultado sobre la posición del estadístico observado dentro de la distribución de los estadísticos simulados?

2. En los casos B y C, explique por qué estos resultados pueden sugerir que el modelo tiene dificultades para reproducir esa característica particular de los datos.

Resolución: 1. y 2.

Caso A: $p_B \approx 0{,}50$

La interpretación adecuada es el **a)** ya que si $p_B \approx 0{,}50$, aproximadamente la mitad de los estadísticos simulados se encuentran por debajo del valor observado y aproximadamente la otra mitad por encima.

Por lo tanto, el estadístico observado se encuentra en una posición relativamente central dentro de la distribución de los estadísticos simulados.

$$\boxed{p_B \approx 0{,}50 \quad \Longrightarrow (y) \text{ está en una zona central}}$$

¿Qué NO significa?

No significa:

$$P(H_0 \text{ es verdadera}) = 0{,}50.$$

El Bayesian p-value no es la probabilidad de que una hipótesis nula sea verdadera.
Tampoco corresponde interpretar automáticamente:

$$p_B > 0{,}05$$

como ‘‘`aceptamos el modelo`’’.
El Bayesian p-value se utiliza aquí como una herramienta de comparación entre una característica observada y su comportamiento bajo la distribución predictiva posterior.

Caso B: $p_B \approx 0{,}02$

Recordemos que $p_B = P\left(T(\tilde{y}) \leq T(y) \mid y\right)$.. Si $p_B \approx 0{,}02$, aproximadamente el $2\,\%$ de los estadísticos simulados son menores o iguales que el observado. Por lo tanto, el estadístico observado se encuentra muy por debajo de la distribución de los estadísticos simulados.
Conceptualmente:

$$\boxed{p_B \approx 0 \quad \Longrightarrow \quad T(y) \text{ es muy bajo respecto de los simulados}}$$

Esto puede indicar que el modelo tiene dificultades para reproducir esa característica particular de los datos.

Caso C: $p_B \approx 0{,}97$

Si $p_B \approx 0{,}97$, aproximadamente el $97\,\%$ de los estadísticos simulados son menores o iguales que el observado. Por lo tanto, el estadístico observado se encuentra muy por encima de la distribución de los estadísticos simulados.
Así:

$$\boxed{p_B \approx 1 \quad \Longrightarrow \quad T(y) \text{ es muy alto respecto de los simulados}}$$

Nuevamente, esto puede sugerir que el modelo tiene dificultades para reproducir esa característica particular.

Observación final: miren el enunciado 1.b). Las probabilidades van entre 0 y 1. ¡Cuidado con su elección! Esos detalles sutiles pueden cambiar los criterios de selección de los incisos.

Ejercicio 7: Se considera el siguiente código:

```
media_observada = y.mean()

medias_simuladas = y_rep.mean(axis=-1)

p_B = np.mean(
     medias_simuladas <= media_observada
)
```

donde `y` contiene los datos observados e `y_rep` contiene réplicas generadas desde la distribución predictiva posterior.

Resolución:

a) La primera línea es:

```
media_observada = y.mean()
```

Por lo tanto, el estadístico elegido es la media: $T(y) = \bar{y}$ donde $\bar{y} = \dfrac{1}{n}\sum_{i=1}^{n} y_i$.

b) La variable:

```
medias_simuladas = y_rep.mean(axis=-1)
```

contiene la media de cada réplica simulada.

Supongamos que tenemos:

$$\tilde{y}^{(1)}, \tilde{y}^{(2)}, \ldots, \tilde{y}^{(S)}.$$

Entonces:

$$\texttt{medias_simuladas} = \left(\bar{\tilde{y}}^{(1)}, \bar{\tilde{y}}^{(2)}, \ldots, \bar{\tilde{y}}^{(S)}\right).$$

Es decir:

$$\boxed{\texttt{medias_simuladas} = T(\tilde{y}^{(1)}), \ldots, T(\tilde{y}^{(S)})}$$

c) La expresión:

```
medias_simuladas <= media_observada
```

compara cada media simulada con la media observada. Por ejemplo, si
`medias_simuladas` $= [10, 12, 15, 8, 13]$ y `media_observada` $= 12$,
entonces:

```
medias_simuladas <= media_observada
```

produce:

$$[\texttt{True}, \texttt{True}, \texttt{False}, \texttt{True}, \texttt{False}].$$

Por lo tanto, estamos identificando cuáles de las medias simuladas cumplen:

$$T(\tilde{y}) \leq T(y).$$

d) En Python, los valores booleanos pueden utilizarse numéricamente:
`True` $= 1$, `False` $= 0$.
Por ejemplo:

$$[\texttt{True}, \texttt{True}, \texttt{False}, \texttt{True}, \texttt{False}]$$

equivale a:

$$[1, 1, 0, 1, 0].$$

Su promedio es:

$$\frac{1+1+0+1+0}{5} = \frac{3}{5} = 0{,}60.$$

Por lo tanto:

$$\boxed{p_B \approx \frac{\#\{T(\tilde{y}^{(s)}) \leq T(y)\}}{S}}$$

donde S es el número de réplicas simuladas. Esto constituye una aproximación Monte Carlo a:

$$P\left(T(\tilde{y}) \leq T(y) \mid y\right).$$

e) Si obtenemos $p_B = 0{,}51$, aproximadamente el 51 % de las medias simuladas son menores o iguales que la media observada.

Por lo tanto, la media observada se encuentra aproximadamente en una posición central dentro de la distribución de medias simuladas.

Podemos decir que: **el modelo parece capaz de reproducir razonablemente la media observada**, al menos respecto de esta característica particular. Esto no significa que el modelo sea "verdadero" o "correcto" en todos los aspectos. La conclusión es más específica: **no se observa una discrepancia importante respecto de la media.**

Ejercicio 8: Considere los siguientes tres esquemas conceptuales:

Modelo A:

$$\theta \longrightarrow y_1, y_2, \ldots, y_n$$

Modelo B:

$$\theta_1 \longrightarrow y_{11}, y_{12}, \ldots, y_{1n_1}$$

$$\theta_2 \longrightarrow y_{21}, y_{22}, \ldots, y_{2n_2}$$

$$\vdots$$

$$\theta_J \longrightarrow y_{J1}, y_{J2}, \ldots, y_{Jn_J}$$

Modelo C:

$$\mu, \sigma \longrightarrow \theta_1, \theta_2, \ldots, \theta_J$$

$$\theta_1 \longrightarrow y_{11}, y_{12}, \ldots, y_{1n_1}$$

$$\theta_2 \longrightarrow y_{21}, y_{22}, \ldots, y_{2n_2}$$

$$\vdots$$

$$\theta_J \longrightarrow y_{J1}, y_{J2}, \ldots, y_{Jn_J}$$

Indique cuál corresponde a:

* modelo con datos agrupados,
* modelo con parámetros independientes por grupo,
* modelo jerárquico.

Justifique brevemente cada elección.

Resolución: En el modelo A todas las observaciones dependen del mismo parámetro θ. Por lo tanto:

$$\boxed{\text{Modelo A = modelo con datos agrupados}}$$

La característica fundamental es que no distinguimos parámetros diferentes para distintos grupos.

En el modelo B cada grupo tiene su propio parámetro:

$$\theta_1, \theta_2, \ldots, \theta_J.$$

No existe una distribución común que conecte esos parámetros.Por lo tanto:

$$\boxed{\text{Modelo B} = \text{parámetros independientes por grupo}}$$

En el modelo C los parámetros de los diferentes grupos están relacionados mediante una distribución común. Así:

$$\boxed{\text{Modelo C} = \text{modelo jerárquico}}$$

Ejercicio 9: Se dispone del siguiente modelo con parámetros independientes para cada grupo:

```
with pm.Model() as modelo:

    p = pm.Beta(
        "p",
        alpha=2,
        beta=2,
        shape=J
    )

    y_obs = pm.Binomial(
        "y_obs",
        n=n,
        p=p,
        observed=y
    )
```

a) Explique por qué, tal como está escrito, los parámetros $p_1, \ldots, p_J$ no comparten información entre grupos.

b) Modifique conceptualmente el modelo para que los parámetros de grupo provengan de una distribución común.

Puede escribir la estructura matemática o pseudocódigo.

c) ¿Qué ventaja podría tener esta modificación cuando algunos grupos tienen pocos datos?

Resolución:

a) La línea:

```
p = pm.Beta(
    "p",
    alpha=2,
    beta=2,
    shape=J
)
```

representa: $p_1, p_2, \ldots, p_J$ con: $p_j \sim \text{Beta}(2, 2)$. Es decir, cada grupo tiene su propio parámetro. Pero los parámetros están definidos de forma independiente. Conceptualmente:

$$p_1 \sim \text{Beta}(2, 2), \quad p_2 \sim \text{Beta}(2, 2), \quad \cdots, \quad p_J \sim \text{Beta}(2, 2),$$

de manera independiente. Por lo tanto, los datos del grupo 1 no modifican directamente el parámetro del grupo 2.

b) Queremos que los parámetros de los grupos provengan de una distribución común. Por ejemplo: $p_j \sim \text{Beta}(\alpha, \beta)$ donde ahora α y β son parámetros comunes. Además, debemos asignarles sus propios priors. Por ejemplo:

$$\alpha \sim \text{Exponencial}(1), \text{ y } \beta \sim \text{Exponencial}(1).$$

Entonces podemos escribir:

```
with pm.Model() as modelo:
alpha = pm.Exponential("alpha", 1)
beta = pm.Exponential("beta", 1)

p = pm.Beta(
    "p",
    alpha=alpha,
    beta=beta,
    shape=J
)

y_obs = pm.Binomial(
    "y_obs",
    n=n,
    p=p,
    observed=y
)
```

La estructura conceptual pasa a ser:

$$\boxed{\alpha, \beta \longrightarrow p_1, p_2, \ldots, p_J}$$

Ahora los parámetros de los distintos grupos están conectados mediante α y β.

Otra parametrización: μ y κ La distribución Beta también puede parametrizarse mediante:

$$\mu = \frac{\alpha}{\alpha + \beta} \text{ y } \kappa = \alpha + \beta.$$

En esta parametrización:

$$\alpha = \mu\kappa \text{ y } \beta = (1 - \mu)\kappa.$$

Entonces podemos pensar conceptualmente el modelo como:

$$p_j \sim \text{Beta}\left(\mu\kappa, (1 - \mu)\kappa\right).$$

La idea jerárquica sigue siendo la misma:

$$\boxed{\text{parámetros comunes} \longrightarrow \text{parámetros de grupo} \longrightarrow \text{datos}}$$

c) Supongamos que tenemos dos grupos: $n_1 = 1000$ y $n_2 = 3$. El grupo 1 tiene mucha información para estimar p_1. El grupo 2, en cambio, tiene muy pocos datos para estimar p_2. En un modelo independiente, el parámetro p_2 depende esencialmente de los datos del grupo 2 y de su prior.

En un modelo jerárquico, el grupo 2 puede aprovechar información sobre la población general de grupos mediante los hiperparámetros α y β. Esto permite el llamado: partial pooling o **agrupamiento parcial**.

Ejercicio 10 – Comparación de distribuciones posteriores Supongamos que luego de ajustar un modelo se obtienen muestras posteriores de las medias de dos grupos:

* $\mu_{laboral}$
* $\mu_{\text{fin de semana}}$

Ambos objetos contienen muestras de la distribución posterior.

a) Escriba una expresión en Python para estimar:

$$P(\mu_{\text{fin de semana}} > \mu_{\text{laboral}} \mid y).$$

b) Explique por qué la proporción de muestras en las que se cumple esa desigualdad puede interpretarse como una probabilidad posterior.

Resolución:

a) Si `mu_laboral` y `mu_fin_semana` contienen muestras de las distribuciones posteriores, podemos calcular:

```
probabilidad = np.mean(
            mu_fin_semana > mu_laboral
           )
```

Es decir:

$$\boxed{\widehat{P} = \frac{\#\{\mu^{(s)}_{\text{fin de semana}} > \mu^{(s)}_{\text{laboral}}\}}{S}}$$

donde S representa el número de muestras posteriores.

b) Las muestras:

$$\mu^{(1)}_{\text{laboral}}, \ldots, \mu^{(S)}_{\text{laboral}}$$

y:

$$\mu^{(1)}_{\text{fin de semana}}, \ldots, \mu^{(S)}_{\text{fin de semana}}$$

representan muestras de las distribuciones posteriores. Para cada iteración s podemos preguntar:

$$¿\mu^{(s)}_{\text{fin de semana}} > \mu^{(s)}_{\text{laboral}}?$$

Cada comparación produce: `True` o `False`. El promedio de esas comparaciones representa la proporción de la distribución posterior conjunta para la cual se cumple la desigualdad. Por lo tanto:

$$\boxed{P\big(\mu_{\text{fin de semana}} > \mu_{\text{laboral}} \mid y\big)}$$

puede aproximarse mediante:

$$\boxed{\frac{\#\{\mu^{(s)}_{\text{fin de semana}} > \mu^{(s)}_{\text{laboral}}\}}{S}}$$

Ejemplo de interpretación

Supongamos que obtenemos:

$$\texttt{np.mean(mu_fin_semana >mu_laboral)} = 0{,}93.$$

Entonces podemos interpretar:

$$P\big(\mu_{\text{fin de semana}} > \mu_{\text{laboral}} \mid y\big) \approx 0{,}93$$

Es decir, dado el modelo y los datos observados, la probabilidad posterior de que la media del fin de semana sea mayor que la media laboral es aproximadamente 0,93.